



**Hochschule
Bonn-Rhein-Sieg**

*University
of Applied Sciences*

Fachbereich Informatik
Department of Computer Sciences

Bachelorarbeit

Studiengang Cyber Security & Privacy

Löschen von PII aus LLM

Experimentelle Untersuchung der Loss-Granularität beim
Gradient-Ascent-Unlearning anhand einer kontrollierten faktischen
Relation

von

Stephan Kleefisch

Erstprüfer: Prof. Dr. Stefan Schiffner
Zweitprüfer: Prof. Dr. Bettina Berendt
Betreuer: Dimitri Staufer

Eingereicht am: 14. September 2026

Eidesstattliche Erklärung

Hiermit versichere ich an Eides statt, dass ich die vorliegende Bachelorthese ohne fremde Hilfe angefertigt und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Alle Teile, die wörtlich oder sinngemäß einer Veröffentlichung entstammen, sind als solche kenntlich gemacht. Die Arbeit wurde noch nicht veröffentlicht oder einer anderen Prüfungsbehörde vorgelegt.

Generative KI wurde im Rahmen dieser Arbeit ausschließlich unterstützend eingesetzt. Die KI-Anwendung ChatGPT wurde zur sprachlichen und stilistischen Überarbeitung von Textpassagen sowie zur Unterstützung bei der Verbesserung und Fehlerbehebung einzelner Implementierungen für Modelltraining und Machine Unlearning verwendet. Die methodische Konzeption, die Durchführung und Auswertung der Experimente sowie die inhaltliche Bewertung der Ergebnisse wurden eigenständig vorgenommen.

Ort, Datum

Unterschrift

Zusammenfassung. Large Language Models können Bestandteile ihrer Trainingsdaten memorisieren und unter geeigneten Eingaben reproduzieren. Dies ist insbesondere bei personenbezogenen Informationen problematisch und motiviert Verfahren des Machine Unlearning. Die vorliegende Arbeit untersucht, wie die Granularität des Forget-Losses die Schwächung einer Zielrelation und die Selektivität der Modelländerung beim Gradient-Ascent-basierten Unlearning beeinflusst. Personenbezogene Informationen bilden dabei den Anwendungskontext. Die experimentelle Untersuchung überträgt diese Fragestellung bewusst auf eine nicht-personenbezogene faktische Relation.

Hierzu wird ein GPT-artiges Decoder-only-Modell mit rund 163 Millionen trainierbaren Parametern von Grund auf auf der Simple English Wikipedia trainiert. Der vollständig bekannte Trainingskorpus ermöglicht die Identifikation expliziter Trainingsbelege für die Relation zwischen Pakistan und Islamabad sowie die Konstruktion eines Referenzmodells, in dessen Trainingskorpus diese Evidenzstellen entfernt werden. Verglichen werden sequenzweites Gradient Ascent und eine token-selektive Variante, bei der ausschließlich relationstragende Tokenpositionen zum Forget-Loss beitragen.

Bei gleicher Lernrate und gleicher Anzahl an Updates führt der token-selektive Forget-Loss zu einer deutlich stärkeren Schwächung der untersuchten Zielrelation. Bei vergleichbarer Zielschwächung bleiben die nicht relationstragenden Positionen der Forget-Sequenzen beim token-selektiven Modellzustand wesentlich stabiler; auch der Validierungsverlust liegt im ausgewählten Vergleich näher am Ausgangsmodell. Dieser lokale Selektivitätsvorteil zeigt sich jedoch nicht durchgängig bei anderen faktischen Informationen.

Die Ergebnisse zeigen damit, dass die Granularität des Forget-Losses die Stärke der Zielschwächung wesentlich beeinflusst und mit unterschiedlichen Selektivitätsmustern der Modelländerung einhergeht. Tokenbezogene Selektivität geht dabei nicht zwangsläufig mit geringeren Kollateraleffekten auf andere faktische Informationen einher.

Schlüsselwörter: Machine Unlearning · Large Language Models · Gradient Ascent · Loss-Granularität · personenbezogene Informationen

Inhaltsverzeichnis

Eidesstattliche Erklärung	2
Abkürzungen	6
1 Einleitung	7
1.1 Zielsetzung und Abgrenzung	7
1.2 Forschungsfragen	8
1.3 Aufbau der Arbeit	8
2 Fachliche Grundlagen	9
2.1 Aufbau und Funktion von Large Language Models	9
2.2 Training autoregressiver Sprachmodelle	11
2.3 Memorization und Extrahierbarkeit	14
2.4 PII und personenbezogene Daten	15
2.5 Machine Unlearning	15
3 Stand der Forschung und verwandte Unlearning-Verfahren	16
3.1 Gradient-Ascent-basiertes Unlearning	16
3.2 Wissensbasiertes Unlearning und Model Editing	17
3.3 Evaluation von LLM-Unlearning	17
3.4 Ableitung des experimentellen Ansatzes	18
4 Aufbau und Vortraining des Basismodells	19
4.1 Datensatz und Datenaufbereitung	19
4.2 Modellarchitektur	19
4.3 Vortraining des Basismodells	20
4.4 Trainingsergebnisse	21
4.5 Explorative Voruntersuchung des Faktenwissens	21
5 Methodik und Versuchsdesign	22
5.1 Untersuchungsansatz und Abgrenzung	22
5.2 Experimentelle Modellzustände	22
5.3 Auswahl der Zielrelation	23
5.4 Konstruktion der Forget-Evidenz	25
5.5 Gradient-Ascent-Varianten	27
5.6 Konstruktion des Referenzkorpus und Referenzmodells	28
6 Evaluationsstrategie	29
6.1 Evaluationsdaten	30
6.2 Zentrale Evaluationsgrößen	31
6.3 Auswertung nach Forschungsfragen	33
7 Ergebnisse	35
7.1 Ausgangszustand des Basismodells	35
7.2 Erste Forschungsfrage – Einfluss der Loss-Granularität auf die Zielschwächung	35
7.3 Zweite Forschungsfrage – Selektivität und Kollateraleffekte	37
7.4 Dritte Forschungsfrage – Vergleich mit dem Referenzmodell	42
8 Diskussion und Limitationen	44

8.1	Erste Forschungsfrage – Einfluss der Loss-Granularität auf die Zielschwächung	44
8.2	Zweite Forschungsfrage – Selektivität und Kollateraleffekte	44
8.3	Dritte Forschungsfrage – Einordnung des Referenzmodells	45
8.4	Bedeutung und Grenzen des kontrollierten Trainingskorpus	46
8.5	Übertragbarkeit auf personenbezogene Informationen und größere Sprachmodelle	47
8.6	Rechtliche Einordnung	47
9	Fazit und Ausblick	47
	Anhang	50
A	Zusätzliche Ergebnisdaten	50
B	Löschspans des Referenzmodells	50
C	Klassifizierte Kandidatenfenster	51
D	Vollständige Evaluationsprompts	53
E	Vollständige Mask-Annotationen	56
F	Quellcode und Reproduzierbarkeit	57

Abbildungsverzeichnis

1	Mittlere Veränderung der NLL der Zielrelation nach 16 Unlearning-Schritten in Abhängigkeit von der Lernrate	36
2	Veränderung der relationstragenden Tokenpositionen in Abhängigkeit von der Veränderung des übrigen Sequenzkontexts. Die Beschriftungen geben die jeweilige Lernrate an.	39
3	Veränderung der Kontrollfakten bei vergleichbarer Zielschwächung	40
4	Zusammenhang zwischen Target- Δ NLL und Veränderung des vollständigen Validierungsverlusts nach 16 Unlearning-Schritten	41

Tabellenverzeichnis

1	Architekturparameter des Basismodells	20
2	Zentrale Hyperparameter des Basismodelltrainings	20
3	Next-Token-Evaluation der Relation zwischen Paris und Frankreich	21
4	Ausgewählte Ergebnisse des Kandidatenscreenings	24
5	Ergebnisse der manuellen Klassifikation der Kandidatenfenster	26
6	Beispiele annotierter Zielpositionen für den token-selektiven Forget-Loss	28
7	Beispiele für Löschspans unterschiedlicher sprachlicher Formen der Zielrelation	29
8	Struktur der Ziel- und Kontrollfakten	31
9	Zuordnung der Evaluationsbestandteile zu den Forschungsfragen	33
10	Ausgangszustand des Basismodells auf der Zielrelation	35
11	Target- Δ NLL nach 16 Updates in Abhängigkeit von der Lernrate	36
12	Vergleich der beiden Gradient-Ascent-Varianten bei vergleichbarer Zielschwächung	38

13	Verhalten des Referenzmodells auf der Zielrelation	42
14	Veränderung der Kontrollgruppen im Referenzmodell gegenüber M_0 ..	43
15	Zusammenfassender Vergleich ausgewählter Modellzustände	43
16	Vollständiger Validierungsverlust der Step-16-Modellzustände	50
17	Löschspans der 16 Evidenzfenster des Referenzmodells	50
18	Klassifizierte Kandidatenfenster der Evidenzanalyse	51
19	Vollständige Prompt- und Zielsequenzen der Faktenevaluation	53
20	Counterfactual-Zielsequenzen der Zielrelation	56
21	Vollständige Mask-Annotationen des token-selektiven Forget-Losses ..	56

Abkürzungen

Abkürzung Bedeutung	
BPE	Byte Pair Encoding
DSGVO	Datenschutz-Grundverordnung
GA	Gradient Ascent
LLM	Large Language Model
NLL	Negative Log-Likelihood
PII	Personally Identifiable Information
PPL	Perplexity

1 Einleitung

Large Language Models (LLM) werden auf Grundlage großer Textsammlungen beziehungsweise Textkorpora trainiert. Unter bestimmten Bedingungen können sie konkrete Inhalte ihrer Trainingsdaten memorisieren und später wörtlich reproduzieren. Carlini et al. [5] zeigten beispielsweise, dass sich Trainingssequenzen aus GPT-2 extrahieren lassen. Enthalten solche Sequenzen personenbezogene Informationen, kann ihre spätere Ausgabe ein Datenschutzrisiko darstellen.

Werden einzelne Informationen nachträglich aus den Trainingsdaten entfernt, verändert dies ein bereits trainiertes Modell nicht automatisch. Dies ist insbesondere im Zusammenhang mit personenbezogenen Informationen relevant: Artikel 16 DSGVO regelt das Recht auf Berichtigung unrichtiger personenbezogener Daten, während Artikel 17 unter bestimmten Voraussetzungen ein Recht auf Löschung vorsieht¹. Ob und unter welchen Bedingungen daraus konkrete Anforderungen an die Veränderung eines trainierten Modells folgen, ist rechtlich und technisch nicht pauschal zu beantworten und wird in den Grundlagen näher eingeordnet.

An diesem Problem setzt das Forschungsfeld Machine Unlearning an. Es befasst sich mit Verfahren, mit denen der Einfluss bestimmter Trainingsdaten aus einem bereits trainierten Modell entfernt oder zumindest reduziert werden soll. Der naheliegende Referenzansatz ist ein vollständiges Retraining ohne die zu vergessenden Daten. Bei großen Modellen ist dieses Vorgehen jedoch mit erheblichem Zeit-, Energie- und Kostenaufwand verbunden [27]. Aus diesem Grund versuchen sogenannte Approximate-Unlearning-Verfahren, den Einfluss der zu vergessenden Daten durch nachträgliche Modelländerungen zu reduzieren und sich dabei dem Verhalten eines ohne diese Daten trainierten Modells anzunähern [27].

1.1 Zielsetzung und Abgrenzung

Personenbezogene Informationen bilden einen wichtigen Anwendungskontext für Machine Unlearning, werden in dieser Arbeit jedoch nicht unmittelbar als experimentelle Zielinformationen verwendet. Stattdessen wird die technische Fragestellung anhand einer faktischen Relation untersucht, also einer konkreten Zuordnung zwischen zwei Entitäten. Dadurch kann eine bereits aus dem ursprünglichen Training stammende Zielinformation unter kontrollierten Bedingungen untersucht werden, ohne sie zuvor durch zusätzliches Fine-Tuning gezielt in das Modell einzubringen. Die Ergebnisse werden daher nicht als direkter Nachweis für die Übertragbarkeit des Verfahrens auf personenbezogene Informationen interpretiert.

¹ Verordnung (EU) 2016/679 des Europäischen Parlaments und des Rates vom 27. April 2016 zum Schutz natürlicher Personen bei der Verarbeitung personenbezogener Daten, zum freien Datenverkehr und zur Aufhebung der Richtlinie 95/46/EG (Datenschutz-Grundverordnung), Art. 16, 17.

Hierfür wird ein selbst trainiertes, vergleichsweise kleines Sprachmodell verwendet, dessen vollständiger Trainingskorporus bekannt ist. Dadurch können konkrete Textstellen identifiziert werden, in denen die ausgewählte Relation explizit ausgedrückt wird. Zusätzlich wird ein Referenzmodell auf einem entsprechend veränderten Trainingskorporus neu trainiert. So lassen sich sowohl die Schwächung der Zielrelation als auch Kollateraleffekte auf nicht adressierte Informationen untersuchen.

Verglichen werden zwei Machine-Unlearning-Varianten, die sich darin unterscheiden, ob der Forget-Loss über alle vorherzusagenden Token einer Trainingssequenz oder nur über ausgewählte, für die Zielrelation relevante Token berechnet wird. Eine Verringerung der Wahrscheinlichkeit der Zielinformation wird dabei nicht als Nachweis verstanden, dass der Einfluss der zugrunde liegenden Trainingsinformation vollständig aus dem Modell entfernt wurde [6].

Die Übertragbarkeit auf größere Modelle wird auf Grundlage der Literatur und der experimentellen Limitationen diskutiert, jedoch nicht als eigenständig empirisch beantwortete Forschungsfrage behandelt.

1.2 Forschungsfragen

Aus dem beschriebenen Versuchsaufbau ergibt sich die Frage, wie sich die Granularität des Forget-Losses sowohl auf die Schwächung der Zielrelation als auch auf die Selektivität der Modelländerung auswirkt. Unter Selektivität wird dabei verstanden, inwieweit die Zielrelation geschwächt werden kann, ohne nicht adressierte Informationen unnötig zu beeinträchtigen.

Im Mittelpunkt steht folgende Forschungsfrage:

Wie beeinflusst die Granularität des Forget-Losses die Schwächung der Zielrelation und die Selektivität der Modelländerung beim Gradient-Ascent-basierten Unlearning?

Zur Beantwortung der Hauptforschungsfrage werden drei Teilfragen untersucht:

1. Wie unterscheiden sich sequenzweiter und token-selektiver Forget-Loss hinsichtlich der Schwächung der Zielrelation?
2. Welche Kollateraleffekte zeigen die beiden Varianten bei vergleichbarer Zielschwächung innerhalb der Forget-Sequenzen, bei Kontrollfakten mit unterschiedlicher Beziehung zur Zielrelation und hinsichtlich der Modell-Utility?
3. Wie lassen sich die durch Unlearning erzeugten Modellzustände anhand derselben Evaluationsgrößen gegenüber einem neu trainierten Referenzmodell einordnen, in dessen Trainingskorporus die identifizierten Evidenzstellen entfernt wurden?

1.3 Aufbau der Arbeit

Kapitel 2 führt zunächst die für die Arbeit erforderlichen technischen und rechtlichen Grundlagen ein. Dazu werden die für das Verständnis des Versuchsaufbaus

relevanten Eigenschaften autoregressiver Sprachmodelle, deren Training sowie die Begriffe Memorization und Extrahierbarkeit erläutert. Anschließend werden personenbezogene Informationen als Anwendungskontext eingeordnet und zentrale Konzepte des Machine Unlearnings eingeführt.

Darauf aufbauend gibt Kapitel 3 einen Überblick über den Stand der Forschung zu Machine Unlearning. Betrachtet werden insbesondere Gradient-Ascent-basierte Verfahren sowie Ansätze zur Evaluation von Unlearning, Modell-Utility und Locality. Aus diesen Arbeiten wird anschließend der experimentelle Ansatz der vorliegenden Untersuchung abgeleitet.

Kapitel 4 beschreibt den Aufbau und das Vortraining des für die Experimente verwendeten Basismodells. Neben Datensatz, Tokenisierung, Modellarchitektur und Trainingskonfiguration wird untersucht, ob faktische Relationen im trainierten Modell ausreichend quantitativ messbar sind, um als Ausgangspunkt für die anschließenden Unlearning-Experimente zu dienen.

Kapitel 5 beschreibt das experimentelle Versuchsdesign. Dazu gehören die Auswahl der Zielrelation und ihrer Trainingsbelege, die beiden untersuchten Gradient-Ascent-Varianten sowie die Konstruktion des Referenzmodells.

Kapitel 6 beschreibt anschließend die Evaluationsstrategie und ordnet die verwendeten Messgrößen und Kontrollgruppen den drei Forschungsfragen zu.

Kapitel 7 stellt die Ergebnisse der Unlearning-Experimente dar. Untersucht werden die Schwächung der Zielrelation, die tokenbezogene Selektivität, Kollateraleffekte auf andere faktische Informationen und die Modell-Utility. Zusätzlich werden die beobachteten Modellzustände mit dem neu trainierten Referenzmodell verglichen.

Kapitel 8 ordnet die Ergebnisse im Hinblick auf die Forschungsfragen ein und diskutiert die Aussagegrenzen des Versuchsaufbaus. Dabei werden insbesondere die Bedeutung des kontrollierten Trainingskorpus, die Übertragbarkeit auf personenbezogene Informationen und größere Sprachmodelle sowie die rechtliche Einordnung betrachtet.

Abschließend fasst Kapitel 9 die zentralen Ergebnisse der Arbeit zusammen und zeigt mögliche Ansatzpunkte für weiterführende Untersuchungen auf.

2 Fachliche Grundlagen

Um die Entstehung von Memorization und die später untersuchten Unlearning-Eingriffe nachvollziehen zu können, werden zunächst die für diese Arbeit relevanten Eigenschaften autoregressiver Transformer-Sprachmodelle erläutert.

2.1 Aufbau und Funktion von Large Language Models

LLM sind neuronale Sprachmodelle, die Wahrscheinlichkeitsverteilungen über Textsequenzen modellieren. Das in dieser Arbeit entwickelte Modell gehört zur Gruppe autoregressiver Decoder-only-Sprachmodelle. Ein autoregressives Sprachmodell verarbeitet eine Textsequenz schrittweise: Für jede Position wird auf Grundlage der bereits vorangegangenen Token eine Wahrscheinlichkeitsverteilung

für das nächste Token berechnet. Dieses Trainingsziel wird als Next-Token-Prediction bezeichnet [25].

Bei der Textgenerierung wird aus dieser Wahrscheinlichkeitsverteilung ein nächstes Token ausgewählt, an den bisherigen Kontext angehängt und anschließend erneut eine Vorhersage für das folgende Token berechnet. Auf diese Weise entsteht eine Textsequenz Token für Token [25].

Für das Verständnis des später untersuchten Unlearning-Verfahrens sind insbesondere die Verarbeitung von Text als Token, die kontextabhängige Berechnung von Next-Token-Wahrscheinlichkeiten und die Anpassung der Modellparameter anhand einer Verlustfunktion relevant. Die folgenden Abschnitte führen daher diejenigen Bestandteile des verwendeten Sprachmodells ein, die für das Verständnis des Basismodells, des Gradient-Ascent-Unlearnings und der anschließenden Evaluation benötigt werden.

Tokenisierung Bevor Text von einem Sprachmodell verarbeitet werden kann, wird er in kleinere Einheiten, sogenannte Token, zerlegt. Jedem Token wird eine numerische ID zugeordnet, die anschließend vom Modell verarbeitet werden kann. Ein Token kann beispielsweise einem vollständigen Wort, einem Wortbestandteil oder einem Satzzeichen entsprechen [25].

Der GPT-2-Tokenizer verwendet eine Byte-Level-Variante des Byte Pair Encoding (BPE) und verfügt über ein Vokabular von 50 257 Token [28,24]. Abhängig von der konkreten Zeichenfolge kann ein Wort durch ein einzelnes oder durch mehrere Token repräsentiert werden.

Für die spätere Faktenevaluation ist diese Segmentierung relevant, da Zielantworten je nach Tokenisierung aus einem oder mehreren Token bestehen können. Beim Prompt „The capital of Pakistan is“ bildet die erwartete Fortsetzung „Islamabad“ beispielsweise ein einzelnes Token; bei mehrteiligen Zielantworten muss dagegen die gesamte Tokenfolge berücksichtigt werden.

Das in dieser Arbeit verwendete Modell ist ein autoregressives Decoder-only-Transformer-Modell [24]. Für das Verständnis des später untersuchten Unlearning-Verfahrens sind insbesondere die Repräsentation der Eingabetoken sowie die kausale Verarbeitung des vorangegangenen Kontexts relevant. Diese beiden Aspekte werden im Folgenden näher erläutert.

Token- und Positions-Embeddings Damit die zuvor erzeugten Token-IDs verarbeitet werden können, werden sie zunächst in Vektorrepräsentationen überführt. Das Modell ordnet jeder Token-ID einen trainierbaren Vektor fester Dimension zu, der als *Token-Embedding* bezeichnet wird. Die Werte der Embeddings werden während des Trainings gemeinsam mit den übrigen Modellparametern angepasst.

Zusätzlich benötigt das Modell Informationen über die Position der Token innerhalb der Eingabesequenz. Hierzu wird jeder Position innerhalb der Eingabesequenz ein eigener Positionsvektor zugeordnet. Token- und Positions-Embedding werden addiert und bilden gemeinsam die Eingabe für die Transformer-Blöcke [23,24].

Self-Attention Self-Attention ermöglicht es dem Modell, die Repräsentation eines Tokens unter Berücksichtigung anderer Positionen derselben Sequenz zu bilden [31]. In autoregressiven Sprachmodellen wird dieser Zugriff durch eine kausale Maske auf bereits vorangegangene Positionen beschränkt. Zukünftige Token stehen für die Vorhersage dadurch nicht zur Verfügung [31,25].

GPT-artige Modelle führen mehrere solcher Attention-Berechnungen parallel aus, was als *Multi-Head Attention* bezeichnet wird [31].

Für den später untersuchten token-selektiven Forget-Loss ist diese Unterscheidung zwischen Kontext und Loss-Position besonders relevant. Nur ausgewählte Zielpositionen tragen dort zum Forget-Loss bei; die übrigen Token werden jedoch nicht aus der Eingabesequenz entfernt. Soweit sie einer ausgewählten Zielposition vorausgehen, können sie weiterhin über die Self-Attention als Kontext für deren Vorhersage berücksichtigt werden.

2.2 Training autoregressiver Sprachmodelle

Vortraining und Fine-Tuning Beim Vortraining wird ein Sprachmodell auf einem umfangreichen Textkorpus trainiert. Im Fall des in dieser Arbeit verwendeten autoregressiven Modells besteht das Trainingsziel darin, für jede Position das jeweils folgende Token vorherzusagen. Dabei lernt das Modell statistische Regelmäßigkeiten des Trainingskorpus und kann auch faktische Zusammenhänge in seinem Modellverhalten abbilden. Als Fine-Tuning wird eine anschließende weitere Anpassung eines bereits trainierten Modells auf zusätzlichen, meist aufgabenspezifischen Daten bezeichnet[25] [3]. Diese Unterscheidung ist für die vorliegende Arbeit relevant, da die experimentell untersuchte Zielrelation bereits aus dem ursprünglichen Training des Modells stammt und nicht erst durch eine zusätzliche Fine-Tuning-Phase gezielt eingebracht wird.

Logits, Softmax und Sprachmodell-Loss Ein autoregressives Sprachmodell gibt für eine Eingabesequenz nicht unmittelbar das nächste Token aus. Stattdessen berechnet es für jede Position zunächst einen Wert für jedes Token des Vokabulars. Aus diesen Werten wird eine Wahrscheinlichkeitsverteilung für das jeweils nächste Token bestimmt. Da sowohl das Training als auch das später untersuchte Gradient-Ascent-Unlearning auf dem daraus berechneten Loss beruhen, werden die hierfür relevanten Größen im Folgenden eingeführt.

Für jede Tokenposition erzeugt das Modell einen Vektor unnormierter Werte über das gesamte Vokabular. Diese Werte werden als *Logits* bezeichnet. Durch Anwendung der Softmax-Funktion werden sie in eine Wahrscheinlichkeitsverteilung überführt [12, S. 181]:

$$p_i = \frac{\exp(z_i)}{\sum_{j=1}^V \exp(z_j)}, \quad (1)$$

wobei z_i den Logit des Tokens i und V die Größe des Vokabulars bezeichnet. Jedem möglichen nächsten Token wird damit eine Wahrscheinlichkeit zugewie-

sen, wobei sich die Wahrscheinlichkeiten über das gesamte Vokabular zu eins summieren.

Für das Training wird bewertet, welche Wahrscheinlichkeit das Modell dem tatsächlich folgenden Token zuweist. Hierzu wird die Kreuzentropie als Verlustfunktion verwendet. Da das korrekte nächste Token als eindeutiges Ziel vorgegeben ist, reduziert sich die Kreuzentropie für eine einzelne Position auf die *Negative Log-Likelihood* (NLL) des beobachteten Zieltokens [12, S. 180]:

$$\mathcal{L}_t = -\log p_\theta(x_t \mid x_{<t}), \quad (2)$$

wobei x_t das tatsächlich folgende Token, $x_{<t}$ den vorausgehenden Kontext und θ die Modellparameter bezeichnet. Weist das Modell dem korrekten Token eine hohe Wahrscheinlichkeit zu, ist dessen NLL gering; bei einer niedrigen Wahrscheinlichkeit steigt sie entsprechend. So entspricht beispielsweise eine Wahrscheinlichkeit von $p = 0,9$ einer NLL von etwa 0,105, während $p = 0,01$ zu einer NLL von etwa 4,605 führt.

Für eine Sequenz mit T vorherzusagenden Tokenpositionen werden die tokenweisen NLL-Werte gemittelt. Der daraus resultierende Sprachmodell-Loss ist

$$\mathcal{L}_{\text{LM}} = -\frac{1}{T} \sum_{t=1}^T \log p_\theta(x_t \mid x_{<t}). \quad (3)$$

Der Sprachmodell-Loss entspricht damit der mittleren NLL der beobachteten Tokenfolge. Beim gewöhnlichen Training wird dieser Loss minimiert, wodurch die Wahrscheinlichkeit der in den Trainingsdaten beobachteten nächsten Token erhöht werden soll [24].

Dieser Zusammenhang ist für das später untersuchte Unlearning unmittelbar relevant. Beim Gradient Ascent wird der Sprachmodell-Loss auf den ausgewählten Forget-Daten maximiert, wodurch die Wahrscheinlichkeit der entsprechenden Zieltoken reduziert werden soll [17,34].

Aus dem mittleren Sprachmodell-Loss lässt sich die *Perplexity* (PPL) als gebräuchliche Bewertungsgröße für Sprachmodelle ableiten. Bei Verwendung des natürlichen Logarithmus gilt

$$\text{PPL} = \exp \left(-\frac{1}{T} \sum_{t=1}^T \log p_\theta(x_t \mid x_{<t}) \right) = \exp(\mathcal{L}_{\text{LM}}). \quad (4)$$

Die Perplexity entspricht damit dem geometrischen Mittel der inversen Wahrscheinlichkeiten, die das Modell den beobachteten Zieltoken zuweist [1, S. 1141]. Anschaulich gibt die Perplexity an, wie gut das Modell die beobachtete Tokenfolge vorhersagt. Eine niedrigere Perplexity bedeutet dabei, dass das Modell den tatsächlich auftretenden Token im Mittel höhere Wahrscheinlichkeiten zuweist.

Da die Perplexity unmittelbar aus dem mittleren Sprachmodell-Loss berechnet wird, stellt sie keine davon unabhängige Bewertungsgröße dar. Sie wird in dieser Arbeit ergänzend verwendet, um Veränderungen des Validierungsverlusts anschaulicher einzuordnen.

Backpropagation und Optimierung Das Training eines neuronalen Sprachmodells verfolgt das Ziel, den Wert der Verlustfunktion durch eine schrittweise Anpassung der Modellparameter zu verringern. Hierzu muss zunächst bestimmt werden, wie sich eine Änderung der einzelnen Parameter auf den Loss auswirkt.

Diese Berechnung erfolgt durch Backpropagation. Dabei werden mithilfe der Kettenregel die partiellen Ableitungen der Verlustfunktion bezüglich der trainierbaren Modellparameter berechnet. Die Gesamtheit dieser Ableitungen bildet den Gradienten der Verlustfunktion. Er beschreibt, in welcher Richtung sich der Loss bei einer Änderung der Modellparameter am stärksten verändert [26,25].

Ein Optimierungsalgorithmus verwendet diese Gradienten anschließend zur Anpassung der Modellparameter. Beim gewöhnlichen Training erfolgt die Aktualisierung grundsätzlich entgegen der Gradientenrichtung, um den Loss zu verringern. Dieses grundlegende Prinzip wird als Gradient Descent bezeichnet [29].

Für das später untersuchte Unlearning ist insbesondere die umgekehrte Optimierungsrichtung relevant: Werden Parameter in Richtung des Gradienten aktualisiert, wird der betrachtete Loss gezielt erhöht. Dieses als Gradient Ascent bezeichnete Prinzip bildet die Grundlage des in dieser Arbeit untersuchten Unlearning-Verfahrens und wird in Abschnitt 3.1 näher beschrieben.

In dieser Arbeit wird der Optimierer AdamW verwendet. Adam berechnet für jeden Parameter exponentiell gleitende Mittelwerte der Gradienten und der quadrierten Gradienten. Auf dieser Grundlage werden die Parameter mit adaptiven Schrittweiten aktualisiert [13]. AdamW ergänzt dieses Verfahren um einen entkoppelten Weight Decay. Weight Decay bewirkt eine zusätzliche, schrittweise Verringerung der Parameterbeträge und kann dadurch regulierend auf das Training wirken [15].

Lernrate und Gradient Clipping Wie stark die Modellparameter bei einem Optimierungsschritt verändert werden, hängt unter anderem von der verwendeten Lernrate ab. Eine höhere Lernrate führt grundsätzlich zu größeren Aktualisierungsschritten, während eine niedrigere Lernrate kleinere Anpassungen bewirkt. Zu große Schritte können den Trainingsverlauf instabil machen, während sehr kleine Lernraten den Lernfortschritt verlangsamen [25].

Die Lernrate muss dabei nicht während des gesamten Trainings konstant bleiben. Beim Vortraining des in dieser Arbeit verwendeten Basismodells wird zunächst eine Warmup-Phase eingesetzt, in der die Lernrate schrittweise bis zu ihrem Maximalwert erhöht wird. Anschließend wird sie entsprechend einem sogenannten Cosine-Decay-Verlauf bis zu einem festgelegten Minimalwert reduziert [31,14,25]. Die konkrete Konfiguration des Lernratenverlaufs wird in Kapitel 4 beschrieben.

Neben der Lernrate kann auch die Größe des berechneten Gradienten die Stärke einer Parameteraktualisierung beeinflussen. Beim *Gradient Clipping* wird die Norm des Gradienten auf einen festgelegten Maximalwert begrenzt. Überschreitet sie diesen Grenzwert, wird der Gradient vor dem Optimierungsschritt

entsprechend skaliert. Dadurch können besonders große Parameteraktualisierungen begrenzt werden [22,25].

Gradient Clipping ist auch für die späteren Unlearning-Experimente relevant. Da unterschiedliche Forget-Loss-Definitionen unterschiedlich große Gradienten erzeugen können, bedeutet die Verwendung derselben Lernrate nicht automatisch, dass beide Verfahren ohne weitere Einschränkungen gleich starke Parameteraktualisierungen erzeugen.

Nach Training und Optimierung liegt schließlich ein Modell vor, dessen gelernte Eigenschaften nur über sein beobachtbares Verhalten untersucht werden können. Für die vorliegende Arbeit ist dabei insbesondere die Frage relevant, in welcher Form Trainingsinformationen im Modellverhalten wieder auftreten können.

2.3 Memorization und Extrahierbarkeit

Für die Bewertung von Machine Unlearning ist zwischen im Modell wirksamen Trainingsinformationen und ihrer beobachtbaren Abrufbarkeit zu unterscheiden. Dass eine Information unter einer bestimmten Eingabe nicht ausgegeben wird, belegt nicht, dass ihr Einfluss aus dem Modell entfernt wurde [4].

Unter *Memorization* wird im Zusammenhang mit Sprachmodellen die Übernahme spezifischer Trainingsinformationen in das Modellverhalten verstanden. Besonders unmittelbar lässt sich diese beobachten, wenn eine Trainingssequenz bei geeigneter Eingabe wörtlich oder nahezu wörtlich reproduziert wird [4].

Davon zu unterscheiden ist die *Extrahierbarkeit*. Sie beschreibt, ob eine solche Information mit einem bestimmten Abfrage- oder Extraktionsverfahren tatsächlich aus dem Modell abgerufen werden kann. Eine Information kann unter einem direkten Prompt nicht beobachtbar sein, unter einer paraphrasierten oder anders kontextualisierten Eingabe jedoch weiterhin mit erhöhter Wahrscheinlichkeit auftreten. Ein erfolgloser Abruf zeigt daher zunächst nur, dass die Information mit der verwendeten Abfrage nicht extrahiert wurde; er belegt keine Entfernung ihres Einflusses aus dem Modell [4].

Zugleich können Sprachmodelle aus ihren Trainingsdaten Muster generalisieren und Informationen aus mehreren oder unterschiedlich formulierten Trainingsbelegen ableiten. Memorization und Generalisierung schließen sich daher nicht gegenseitig aus [4].

Für die vorliegende Arbeit hat diese Unterscheidung zwei Konsequenzen. Erstens wird eine verringerte Wahrscheinlichkeit der Zielantwort nicht als Nachweis einer vollständigen Entfernung der zugrunde liegenden Trainingsinformation interpretiert. Zweitens stellen die im Trainingskorpus identifizierten expliziten Textstellen zwar konkrete Trainingsbelege der Zielrelation dar, müssen jedoch nicht deren vollständige Evidenzbasis bilden. Das neu trainierte Referenzmodell ermöglicht daher lediglich zu untersuchen, wie sich das Entfernen dieser identifizierten Evidenzstellen auf das beobachtbare Modellverhalten auswirkt.

2.4 PII und personenbezogene Daten

Der Begriff *Personally Identifiable Information* (PII) wird insbesondere im englischsprachigen technischen Kontext verwendet und bezeichnet beispielsweise nach NIST Informationen, durch die eine Person identifiziert beziehungsweise von anderen unterschieden werden kann oder die mit einer Person verknüpft werden können [18].

Die DSGVO verwendet dagegen den Begriff der personenbezogenen Daten und definiert diese in Artikel 4 Nummer 1 als Informationen, die sich auf eine identifizierte oder identifizierbare natürliche Person beziehen². Beide Begriffe weisen inhaltliche Überschneidungen auf, werden in dieser Arbeit jedoch nicht als vollständig gleichbedeutend behandelt. Sie bilden den Anwendungskontext der Arbeit, die experimentelle Untersuchung abstrahiert davon jedoch bewusst auf eine nicht-personenbezogene faktische Relation. Die technischen Ergebnisse werden daher weder als Nachweis einer vollständigen Entfernung personenbezogener Daten aus einem Modell noch als Nachweis der Erfüllung datenschutzrechtlicher Löschanforderungen interpretiert.

2.5 Machine Unlearning

Begriff und Zielsetzung Machine Unlearning bezeichnet Verfahren, die den Einfluss definierter Trainingsdaten nachträglich aus einem trainierten Modell entfernen oder reduzieren sollen. Hierzu wird häufig zwischen einem zu vergessenden Teil der Trainingsdaten (*Forget Set*) und den verbleibenden Daten (*Retain Set*) unterschieden [17].

Als konzeptionelle Referenz dient ein erneutes Training ohne das Forget Set. Ein Unlearning-Verfahren soll einen Modellzustand erzeugen, der einem solchen Retraining möglichst nahekommt, ohne dessen vollständigen Aufwand zu erfordern [27].

Exact und Approximate Unlearning Beim Exact Unlearning soll ein durch Unlearning erzeugtes Modell derselben Verteilung möglicher Modellzustände folgen wie ein Modell, das mit demselben Lernverfahren von Grund auf ohne die zu vergessenden Trainingsdaten trainiert wurde [2,11]. Die Verteilung entsteht dabei durch zufällige Komponenten des Trainings, etwa die Initialisierung oder die Reihenfolge der Trainingsdaten.

Approximate Unlearning lockert die Forderung vollständiger Übereinstimmung und erlaubt eine begrenzte Abweichung von der entsprechenden Referenzverteilung [27].

In dieser Arbeit wird keine formale Garantie des Unlearnings geprüft. Das neu trainierte Referenzmodell dient stattdessen als empirischer Vergleichszustand, der

² Verordnung (EU) 2016/679 des Europäischen Parlaments und des Rates vom 27. April 2016 zum Schutz natürlicher Personen bei der Verarbeitung personenbezogener Daten, zum freien Datenverkehr und zur Aufhebung der Richtlinie 95/46/EG (Datenschutz-Grundverordnung)

anhand der in Abschnitt 6 definierten beobachtbaren Größen mit den Unlearning-Modellen verglichen wird.

Removal und Output Suppression Cooper et al. unterscheiden zwischen der Entfernung des Einflusses bestimmter Trainingsdaten (*Removal*) und der Unterdrückung bestimmter Inhalte in den Modellausgaben (*Output Suppression*) [6].

Output Suppression zielt darauf ab, bestimmte Inhalte nicht oder nur mit geringerer Wahrscheinlichkeit zu generieren. Eine erfolgreiche Unterdrückung einer Ausgabe belegt jedoch nicht, dass der Einfluss der zugrunde liegenden Trainingsdaten entfernt wurde. Umgekehrt kann auch ein ohne bestimmte Trainingsdaten trainiertes Modell ähnliche Informationen aus anderen Daten oder gelernten Mustern ableiten. Beide Zielsetzungen müssen deshalb getrennt betrachtet werden [6].

3 Stand der Forschung und verwandte Unlearning-Verfahren

Dieses Kapitel ordnet die für die vorliegende Untersuchung relevanten Unlearning-Ansätze und Evaluationskonzepte in den Stand der Forschung ein. Zunächst wird Gradient-Ascent-basiertes Unlearning als Ausgangspunkt der experimentellen Untersuchung betrachtet. Anschließend werden verwandte wissensbasierte Ansätze sowie Anforderungen an die Evaluation diskutiert, aus denen schließlich der experimentelle Ansatz dieser Arbeit abgeleitet wird.

3.1 Gradient-Ascent-basiertes Unlearning

Gradient Ascent stellt eine einfache Baseline für approximatives Unlearning in Sprachmodellen dar. Dabei wird der gewöhnliche Sprachmodell-Loss auf den Forget-Daten maximiert, um deren Wahrscheinlichkeit unter dem Modell zu reduzieren [17,34].

Für die Modellparameter θ , die Lernrate λ und den Forget-Loss $\mathcal{L}_f$ lässt sich ein Gradient-Ascent-Update vereinfacht als

$$\theta_{t+1} = \theta_t + \lambda \nabla_{\theta} \mathcal{L}_f(\theta_t) \quad (5)$$

darstellen.

Der Vorteil des Verfahrens liegt in seiner einfachen Anwendbarkeit, da für das Unlearning zunächst nur die Forget-Daten benötigt werden. Starke Updates können jedoch auch die Leistung auf nicht adressierten Daten beeinträchtigen [34]. Für die vorliegende Arbeit eignet sich Gradient Ascent daher als bewusst einfache Baseline, an der sich der Einfluss unterschiedlicher Definitionen des Forget-Losses untersuchen lässt.

Neuere Arbeiten untersuchen zudem feingranularere Varianten, bei denen nicht alle Token einer Forget-Sequenz gleichermaßen zum Unlearning-Loss beitragen. Feng et al. verwenden hierzu ein adaptives Gradient-Ascent-Ziel mit

feingranularer Kontrolle auf Tokenebene [10]. Wan et al. schlagen mit *Selective Unlearning* einen Ansatz vor, der forget-spezifische Token automatisiert identifiziert und den Unlearning-Loss gezielt auf die ausgewählten Bereiche beschränkt [32]. Damit besteht ein direkter Forschungsbezug zur in dieser Arbeit untersuchten Granularität des Forget-Losses.

3.2 Wissensbasiertes Unlearning und Model Editing

Neben den bisher betrachteten GA-Verfahren wurden für Sprachmodelle in der Forschung auch Ansätze untersucht, die auf die gezielte Veränderung größerer Wissensbereiche oder einzelner faktischer Assoziationen abzielen. Die folgenden Beispiele sind für diese Arbeit aus zwei Gründen relevant: Sie verdeutlichen zum einen die Abgrenzung zwischen einer beobachtbaren Veränderung des Modellverhaltens und der Entfernung des Einflusses ursprünglicher Trainingsdaten. Zum anderen zeigen sie, wie gezielte Wissensänderungen hinsichtlich ihrer Generalisierung und ihrer Auswirkungen auf nicht adressierte Informationen bewertet werden [8,19].

Wissensbezogenes Unlearning: Who’s Harry Potter? Eldan und Russinovich untersuchten das approximative Entfernen eines größeren Wissensbereichs am Beispiel der Harry-Potter-Bücher aus LLaMA 2 [8]. Ziel war es, Harry-Potter-bezogene Ausgaben des Modells durch gezielte Modellanpassungen zu reduzieren. Spätere Untersuchungen zeigten jedoch, dass unter erweiterten Frage-Antwort-, Repräsentations- und Extraktionstests weiterhin entsprechendes Wissen nachweisbar sein kann [16]. Das Beispiel verdeutlicht damit, dass eine reduzierte sichtbare Ausgabe zielbezogener Inhalte nicht automatisch mit einer vollständigen Entfernung des zugrunde liegenden Wissens gleichzusetzen ist.

ROME: Ein Model-Editing-Verfahren ROME ist für die gezielte Änderung faktischer Assoziationen konzipiert und kein datensatzbezogenes Unlearning-Verfahren. Die Evaluation von ROME berücksichtigt neben der Wirksamkeit eines Edits auch dessen Generalisierung auf alternative Formulierungen sowie seine Auswirkungen auf nicht betroffene Fakten [19]. Damit liefert ROME insbesondere einen Bezugspunkt für die spätere Bewertung, wie selektiv eine gezielte Veränderung faktischen Wissens ausfällt.

3.3 Evaluation von LLM-Unlearning

Die Bewertung eines Unlearning-Verfahrens sollte nicht auf eine einzelne direkte Promptform oder allein auf die Veränderung der Forget-Daten beschränkt werden. Relevant ist zunächst, ob eine beobachtete Zielschwächung auch unter veränderten Abfragen bestehen bleibt. Wang et al. untersuchen hierzu unter anderem paraphrasierte und relationell umgekehrte Abfragen [33]. Parii et al. betrachten im UnlearnPII-Benchmark zusätzlich adversariale Abfragen sowie den Erhalt der Modell-Utility [21].

Darüber hinaus ist eine Verschlechterung der Modellleistung auf den zu vergessenden Daten allein kein hinreichendes Kriterium für erfolgreiches Unlearning. Neben der Zielschwächung sollte deshalb auch betrachtet werden, inwieweit die Leistung auf nicht adressierten Informationen erhalten bleibt. Empirische LLM-Unlearning-Benchmarks berücksichtigen diese Anforderungen daher gemeinsam [7].

Einen frühen Benchmark für diese Fragestellung im Kontext generativer Sprachmodelle stellt TOFU (*Task of Fictitious Unlearning*) dar. TOFU verwendet synthetisch erzeugte Autorenprofile mit Frage-Antwort-Paaren und definiert Teilmengen dieser Profile als Forget Set. Die Evaluation betrachtet sowohl die sogenannte *Forget Quality* als auch die verbleibende Modell-Utility und nutzt zusätzlich Modelle, die die Forget-Daten nicht gelernt haben, als Referenz [17].

Mit MUSE (*Machine Unlearning Six-Way Evaluation*) schlagen Shi et al. einen breiter angelegten Evaluationsrahmen vor. Dieser betrachtet sechs Eigenschaften eines unlearnnten Sprachmodells: die Reduktion wörtlicher Memorization, die Reduktion inhaltlichen Wissens, Privacy Leakage, den Erhalt der Modell-Utility, die Skalierbarkeit bei größeren Löschanfragen sowie die Stabilität bei wiederholten Unlearning-Vorgängen [30]. MUSE verdeutlicht damit, dass die Bewertung von Unlearning nicht auf eine einzelne Forget-Metrik reduziert werden kann.

Bei gezielten Veränderungen faktischen Wissens ist zusätzlich relevant, wie stark sich eine Modelländerung auf andere Informationen auswirkt. In der Knowledge-Editing-Literatur werden verwandte Anforderungen unter Begriffen wie *Specificity* und *Locality* untersucht. Der CounterFact-Benchmark bewertet beispielsweise, ob eine gezielte Faktenänderung auf alternative Formulierungen generalisiert und gleichzeitig nicht betroffene Fakten möglichst unverändert lässt [19,20].

Die vorliegende Arbeit verwendet *Selektivität* als übergeordneten Arbeitsbegriff dafür, inwieweit eine gezielte Modelländerung auf die adressierten Informationen begrenzt bleibt. Der Begriff steht damit in enger Beziehung zu den in der Knowledge-Editing-Literatur verwendeten Konzepten *Specificity* und *Locality*, wird hier jedoch nicht als Übernahme einer einzelnen etablierten Benchmark-Metrik verstanden. Selektivität wird in der vorliegenden Untersuchung vielmehr auf mehreren Ebenen anhand der Forget-Sequenzen, der Counterfactuals, der Kontrollfakten und der Modell-Utility betrachtet.

Aus diesen Arbeiten ergibt sich, dass Zielschwächung, Robustheit gegenüber veränderten Abfragen, Kollateraleffekte und der Erhalt der Modell-Utility gemeinsam betrachtet werden sollten.

3.4 Ableitung des experimentellen Ansatzes

Aus dem Forschungsstand wird für die vorliegende Arbeit ein kontrollierter Vergleich zweier Gradient-Ascent-Varianten abgeleitet. Dabei wird die in feingranularen und selektiven Unlearning-Ansätzen verfolgte Grundidee aufgegriffen, den Forget-Loss nicht gleichmäßig über sämtliche Token einer Forget-Sequenz zu berechnen.

Die vorliegende Untersuchung verwendet hierfür eine bewusst einfache und kontrollierte Operationalisierung: Für jedes Evidenzfenster wird manuell eine relationstragende Zielposition annotiert. Die Bezeichnung *token-selektiver Forget-Loss* bezeichnet im Folgenden diese konkrete Variante.

Beide Varianten verwenden dieselben Forget-Sequenzen, unterscheiden sich jedoch darin, ob sämtliche vorherzusagenden Tokenpositionen oder ausschließlich ausgewählte relationstragende Positionen zum Forget-Loss beitragen. Untersucht wird, wie sich diese Loss-Granularität auf die Schwächung der Zielrelation, auf Kollateraleffekte bei unterschiedlich zur Zielrelation stehenden Kontrollfakten und auf die Modell-Utility auswirkt. Zusätzlich werden die resultierenden Modellzustände mit einem neu trainierten Referenzmodell verglichen.

4 Aufbau und Vortraining des Basismodells

Dieses Kapitel beschreibt den Datensatz, die Modellarchitektur und das Vortraining des Basismodells, das als Ausgangspunkt der späteren Unlearning-Experimente dient. Abschließend wird geprüft, ob faktische Relationen im Modellverhalten probabilistisch hinreichend deutlich messbar sind, um als Grundlage für die anschließende Evaluation zu dienen.

4.1 Datensatz und Datenaufbereitung

Als Trainingsgrundlage dient der *Plain Text Wikipedia – Simple English*-Datensatz³. Der englischsprachige Wikipedia-Korpus wurde gewählt, weil sein Umfang ein vollständiges Training des Basismodells mit den verfügbaren Rechenressourcen ermöglicht und zugleich eine gezielte Suche nach Textstellen im Trainingskorpus erlaubt, die faktische Relationen explizit ausdrücken.

Nach der Tokenisierung umfasst der Datensatz insgesamt 42 618 609 Token. Die tokenisierte Datenmenge wird zunächst im Verhältnis 90/10 in Trainings- und Validierungsdaten (sogenannte Splits) aufgeteilt. Erst anschließend werden aus beiden Teilmengen separat Sequenzen mit einer Länge von jeweils 1 024 Token gebildet. Diese Sequenzlänge entspricht zugleich der Kontextlänge des Modells, also der maximalen Anzahl von Token, die innerhalb einer Eingabesequenz gemeinsam verarbeitet werden.

Durch die Aufteilung vor der Bildung dieser Sequenzen wird verhindert, dass eine Sequenz gleichzeitig Token aus dem Trainings- und dem Validierungsbereich enthält.

4.2 Modellarchitektur

Das Basismodell ist ein GPT-artiges Decoder-only-Transformer-Modell, dessen Implementierung sich an GPT-2 [24] und Raschka [25] orientiert. Die wesentlichen Architekturparameter sind in Tabelle 1 zusammengefasst.

³ Verfügbar unter: <https://www.kaggle.com/datasets/ffatty/plain-text-wikipedia-simpleenglish>

Tabelle 1. Architekturparameter des Basismodells

Parameter	Wert
Vokabulargröße	50 257
Kontextlänge	1 024 Token
Embedding-Dimension	768
Attention-Heads	12
Transformer-Blöcke	12
Dropout-Rate	0,1
QKV-Bias	deaktiviert

Die Dimensionsparameter orientieren sich an der kleinen GPT-2-Variante [24]. Aufgrund von Unterschieden in der Implementierung, insbesondere getrennten Token-Embedding- und Output-Projektionsmatrizen, umfasst das Modell 163 009 536 trainierbare Parameter.

4.3 Vortraining des Basismodells

Das Basismodell wurde mit neuer zufälliger Initialisierung von Grund auf trainiert. Die zentralen Trainingsparameter sind in Tabelle 2 zusammengefasst.

Tabelle 2. Zentrale Hyperparameter des Basismodelltrainings

Parameter	Wert
Stride	1 024 Token
Batch-Größe	4
Geplante Epochen	5
Peak-Lernrate	5×10^{-4}
Warmup-Schritte	1 000
Minimale Lernrate	1×10^{-6}
Weight Decay	0,1
Maximale Gradientennorm	1,0
Zufalls-Seed	123

Die Batch-Größe gibt dabei an, wie viele Trainingssequenzen gemeinsam für einen Optimierungsschritt verarbeitet werden. Eine Epoche bezeichnet einen vollständigen Durchlauf durch den Trainingsdatensatz. Das Training war für fünf Epochen mit insgesamt etwa 46 820 Optimierungsschritten vorgesehen und endete bei Schritt 46 460. Damit wurden rund 99,2 % des geplanten Trainingsumfangs erreicht. Da sich der Validierungsverlust gegen Ende des Trainings stabilisiert hatte, wird der bei diesem Schritt gespeicherte Modellzustand im Folgenden als Basismodell M_0 verwendet.

4.4 Trainingsergebnisse

Während des Vortrainings sanken sowohl Trainings- als auch Validierungsverlust deutlich. Der Validierungsverlust fiel von etwa 6,40 zu Beginn des Trainings auf etwa 2,92 gegen dessen Ende. Der letzte regulär protokollierte Trainingsverlust betrug bei Schritt 46 000 etwa 2,68, der entsprechende Validierungsverlust etwa 2,92. Gegen Ende des Trainings zeigte der Validierungsverlust keinen systematischen Anstieg, sondern stabilisierte sich auf diesem Niveau.

Die während des Trainings berichteten Validierungswerte wurden jeweils über 50 Batches bestimmt und dienen ausschließlich dem Monitoring des Trainingsverlaufs. Sie sind daher nicht unmittelbar mit dem später über sämtliche Validierungsfenster berechneten vollständigen Validierungsverlust vergleichbar.

4.5 Explorative Voruntersuchung des Faktenwissens

Da das Modell ausschließlich auf Next-Token-Prediction trainiert und nicht als Frage-Antwort- oder Instruktionsmodell feinabgestimmt wurde, ist die frei generierte Antwort nur eingeschränkt zur Bewertung faktischen Wissens geeignet. Stattdessen werden Wahrscheinlichkeit und Rang der erwarteten Fortsetzung innerhalb der Next-Token-Verteilung betrachtet.

Als Voruntersuchung zur Evaluierbarkeit faktischer Relationen und zur Entwicklung des Kandidatenscreenings wurde zunächst der Prompt „Paris is the capital of“ untersucht. Das korrekte Token „ France“ erhielt dabei eine Wahrscheinlichkeit von ungefähr 8,75 % und Rang 2. Das wahrscheinlichste Token war „ the“ mit ungefähr 71,30 %. Greedy Decoding erzeugte deshalb die Fortsetzung

„Paris is the capital of the district of Paris [...]“

Die korrekte Antwort wird somit vom Modell berücksichtigt, jedoch durch eine statistisch wahrscheinlichere sprachliche Fortsetzung überlagert.

Zur Prüfung der Promptabhängigkeit wurden fünf Formulierungen verwendet. Tabelle 3 zeigt die Ergebnisse.

Prompt	Ziel	Rang	Wahrscheinlichkeit
Paris is the capital of	France	2	0,0875
Paris is the capital city of	France	2	0,1374
Paris is the capital and largest city of	France	2	0,1905
The capital of France is	Paris	2	0,0792
France has its capital in	Paris	2	0,0841

Tabelle 3. Next-Token-Evaluation der Relation zwischen Paris und Frankreich

Bei allen untersuchten Formulierungen erreichte die korrekte Fortsetzung Rang 2. Die Relation war damit in dieser Voruntersuchung über mehrere Promptformulierungen sowie in beiden Relationsrichtungen probabilistisch messbar. Dies

zeigt, dass das beobachtete Modellverhalten nicht auf eine einzelne der getesteten Promptformulierungen beschränkt ist.

Explorative Prüfungen weiterer faktischer Relationen zeigten ein vergleichbares Muster: Erwartete Fortsetzungen lagen häufig unter den wahrscheinlichsten Token, ihre absoluten Wahrscheinlichkeiten unterschieden sich jedoch deutlich zwischen den untersuchten Fakten.

Diese Voruntersuchung zeigte damit, dass faktische Relationen im Basismodell probabilistisch messbar sind und über unterschiedliche Promptformulierungen untersucht werden können. Sie bildete den Ausgangspunkt für das systematische Kandidatenscreening in Abschnitt 5.

5 Methodik und Versuchsdesign

Dieses Kapitel beschreibt den kontrollierten Versuchsaufbau, mit dem der Einfluss der Forget-Loss-Granularität untersucht wird. Zunächst werden die Untersuchungslogik und die betrachteten Modellzustände festgelegt. Anschließend werden die Zielrelation und ihre Trainingsbelege, die beiden Gradient-Ascent-Varianten sowie die Konstruktion des Referenzmodells beschrieben.

5.1 Untersuchungsansatz und Abgrenzung

Der vollständige Zugriff auf den Trainingskorpus ermöglicht es, die Zielrelation mit konkreten Trainingsbelegen zu verknüpfen und neben semantisch verwandten Kontrollfakten auch Informationen aus demselben Trainingskontext zu untersuchen.

Die experimentelle Untersuchung verwendet keine nachträglich eingebrachten personenbezogenen Informationen, sondern eine bereits im Verhalten des Basismodells messbare faktische Relation. Dadurch wird vermieden, dass eine zusätzliche Fine-Tuning-Phase selbst Teil des zu untersuchenden Effekts wird.

Die experimentell variierte Größe ist die *Granularität des Forget-Losses*. Darunter wird in dieser Arbeit verstanden, welche Tokenpositionen einer Forget-Sequenz in die Berechnung des Forget-Losses eingehen.

5.2 Experimentelle Modellzustände

Für das Experiment werden mehrere Modellzustände unterschieden:

1. **Basismodell** M_0 : das auf dem ursprünglichen Trainingskorpus trainierte Ausgangsmodell;
2. **Modell nach sequenzweisem Unlearning** M_U^{seq} : aus M_0 durch Gradient Ascent mit sequenzweisem Forget-Loss erzeugter Modellzustand;
3. **Modell nach token-selektivem Unlearning** M_U^{tok} : aus M_0 durch Gradient Ascent mit token-selektivem Forget-Loss erzeugter Modellzustand;
4. **Referenzmodell** M_{ref} : vollständig neu auf einem veränderten Trainingskorpus trainiertes Modell, aus dem die ausgewählten relationstragenden Textstellen entfernt wurden.

5.3 Auswahl der Zielrelation

Aufgrund des erforderlichen manuellen Screenings der Trainingsbelege sowie des zusätzlichen Trainings eines Referenzmodells wird die Untersuchung als kontrollierte Fallstudie einer einzelnen faktischen Relation durchgeführt. Ziel ist damit nicht, die Ergebnisse über unterschiedliche Faktenklassen hinweg zu generalisieren, sondern die Auswirkungen der Loss-Granularität für einen nachvollziehbar ausgewählten Einzelfall detailliert zu untersuchen.

Die begrenzte Anzahl relevanter Trainingsstellen ist dabei nicht nur eine praktische Einschränkung, sondern ermöglicht zugleich eine vollständige manuelle Prüfung und eine nachvollziehbare Zuordnung der späteren Unlearning-Eingriffe zu konkreten Trainingsbelegen.

Aus einer explorativen Faktenprüfung wurden Kriterien abgeleitet, anhand derer eine geeignete Zielrelation für die anschließenden kontrollierten Unlearning-Versuche ausgewählt wurde.

Kriterien des Kandidatenscreenings Da der enzyklopädische Korpus eine große Zahl möglicher Faktenrelationen enthält, wurde die Kandidatensuche anhand mehrerer Kriterien eingegrenzt.

- Die Zielrelation muss im Verhalten des Basismodells quantitativ messbar sein. Die erwartete Fortsetzung sollte über mehrere geeignete Promptformulierungen eine hohe Rangposition beziehungsweise Modellwahrscheinlichkeit erreichen.
- Die Relation muss durch explizite Textstellen im bekannten Trainingskorpus nachvollziehbar belegt werden können.
- Die Anzahl relevanter Korpusstellen soll eine vollständige manuelle Prüfung der Kandidaten ermöglichen.
- Die erwartete Zielantwort soll möglichst eindeutig sein, sodass alternative ebenfalls korrekte Fortsetzungen die Interpretation der Modellwahrscheinlichkeit nicht unnötig erschweren.
- Die Tokenisierung der Zielantwort soll eine zuverlässige probabilistische Evaluation ermöglichen und möglichst wenige Token umfassen.
- Für die Relation müssen geeignete verwandte sowie unabhängige Kontrollfakten konstruiert werden können.

Ausgewählte Zielrelation Die explorative Faktenevaluation zeigte insbesondere für Hauptstadtbeziehungen ein zuverlässig messbares Modellverhalten. Daher wurde die Relationsklasse

capital(country, city)

für das weitere Screening verwendet.

Die Auswertung umfasste insgesamt 52 Hauptstadtbeziehungen. Für jede Relation wurden vier Promptformulierungen verwendet: zwei direkte Prompts von Land zu Hauptstadt und zwei inverse Prompts von Hauptstadt zu Land, wobei

jeweils eine der beiden Formulierungen paraphrasiert war. Das Screening diente ausschließlich der vergleichenden Kandidatenauswahl. Für die anschließende Unlearning-Evaluation wurde ein separates finales Set aus fünf Zielprompts festgelegt.

Auf Grundlage der zuvor definierten Auswahlkriterien wurde die Relation

capital(Pakistan, Islamabad)

als Zielrelation ausgewählt. Ausschlaggebend war nicht die niedrigste NLL allein, sondern die Kombination aus deutlich messbarem Ausgangssignal, einfacher Tokenisierung und einer für die manuelle Evidenzanalyse handhabbaren Anzahl von Korpusfundstellen. Tabelle 4 ordnet diese Auswahl gegenüber weiteren geeigneten Kandidaten ein.

Tabelle 4. Ausgewählte Ergebnisse des Kandidatenscreenings

Relation	mittl. NLL	Median Rang	Ziel-tokens	Objekt-vorkommen
Mexiko–Mexico City	1,555	1,5	2	609
Argentinien–Buenos Aires	1,577	1,5	2	758
Pakistan–Islamabad	1,941	1,5	1	143
Schweden–Stockholm	2,074	1,5	1	854
Japan–Tokyo	2,345	1,5	1	1 954
Frankreich–Paris	2,595	2,0	1	5 356
Deutschland–Berlin	2,768	1,5	1	2 472

Die mittlere NLL bezeichnet den Mittelwert über die vier im Screening verwendeten Promptformulierungen. Der Median-Rang gibt den Median des Ranges des jeweils ersten erwarteten Zieltokens an. Die Spalte „Zieltokens“ bezeichnet die Anzahl der Token, aus denen die Hauptstadtbezeichnung bei der direkten Abfragerichtung besteht. Die Objektvorkommen wurden als Häufigkeit der jeweiligen Hauptstadtbezeichnung im Gesamtkorpus vor der Aufteilung in Trainings- und Validierungsdaten bestimmt. Sie entsprechen nicht der Anzahl relationstragender Evidenzstellen, sondern dienen als Indikator für den Umfang der anschließend manuell zu prüfenden Korpusfundstellen.

Die Gegenüberstellung zeigt, warum andere ebenfalls gut messbare Kandidaten nicht ausgewählt wurden. Mit mittleren NLL-Werten von 1,555 beziehungsweise 1,577 zeigten Mexiko–Mexico City und Argentinien–Buenos Aires ein stärkeres Ausgangssignal als Pakistan–Islamabad. Beide Hauptstadtbezeichnungen bestehen in der verwendeten Tokenisierung jedoch aus zwei Token. Bei Mexico City kommt hinzu, dass der Ländername „Mexico“ Bestandteil der Hauptstadtbezeichnung ist. Dadurch entsteht eine unmittelbare lexikalische Überschneidung zwischen Subjekt und Objekt der Relation, die insbesondere die Interpretation inverser Abfragen erschwert.

Stockholm, Tokyo, Paris und Berlin bestehen zwar jeweils aus einem einzelnen Token, ihre Hauptstadtbezeichnungen treten im Korpus jedoch deutlich häufiger auf als Islamabad. Die Objektfrequenz wurde daher bei der Kandidatenauswahl als Indikator für einen potenziell höheren Umfang der anschließenden Korpusanalyse berücksichtigt. Sie erlaubt jedoch keine direkte Aussage über die Anzahl tatsächlich relationstragender Evidenzstellen.

Pakistan–Islamabad weist mit einer mittleren NLL von 1,941 und einem medianen First-Token-Rang von 1,5 ebenfalls ein deutlich messbares Ausgangssignal auf. Gleichzeitig besteht die Zielantwort „Islamabad“ in der verwendeten GPT-2-Tokenisierung aus einem einzelnen Token und tritt mit 143 Vorkommen vergleichsweise selten im Gesamtkorpus auf. Damit erfüllt die Relation die für den Versuchsaufbau relevante Kombination aus probabilistischer Messbarkeit, einfacher Tokenisierung und handhabbarem Umfang der anschließenden Evidenzanalyse.

5.4 Konstruktion der Forget-Evidenz

Die in den Grundlagen eingeführte allgemeine Forget-Set-Notation wird für den experimentellen Aufbau weiter differenziert. Grund dafür ist, dass die beiden Gradient-Ascent-Varianten und das Referenztraining nicht auf derselben Granularität operieren. Als E_F wird zunächst die Menge der ausgewählten Evidenzstellen bezeichnet, welche die Zielrelation im Trainingskorpus explizit ausdrücken. Als W_F sind die zugehörigen 1024-Token Trainingsfenster zusammengefasst. Für jedes Trainingsfenster $w \in W_F$ bezeichnet S_w die Menge derjenigen Tokenpositionen, die beim token-selektiven GA zum Forget-Loss beitragen. Für Full-Sequence GA werden die zu diesen Stellen gehörenden Trainingssequenzen verwendet. Beim token-selektiven GA bleibt dieselbe Sequenz als Modellkontext erhalten, zum Forget-Loss tragen jedoch nur ausgewählte Tokenpositionen bei. Für das Referenztraining werden dagegen zusammenhängende relationstragende Textstellen aus dem ursprünglichen Trainingskorpus entfernt.

Korpussuche Zur Identifikation möglicher Trainingsbelege der Zielrelation wurde der Trainingssplit zunächst automatisiert nach gemeinsamen Vorkommen der Begriffe „Pakistan“, „Islamabad“ und „capital“ durchsucht. Als Kandidat wurde ein Trainingsfenster berücksichtigt, wenn alle drei Begriffe innerhalb desselben 1024-Token-Fensters vorkamen. Dieser Filter reduzierte die Menge auf insgesamt 35 Kandidatenfenster.

Das gemeinsame Auftreten der drei Begriffe wurde dabei lediglich als Suchheuristik verwendet und noch nicht als Nachweis dafür interpretiert, dass das jeweilige Fenster die Zielrelation tatsächlich ausdrückt. Daher wurden sämtliche 35 Kandidaten anschließend manuell inhaltlich klassifiziert.

Klassifikation der Evidenzstellen Die 35 Kandidatenfenster wurden anschließend manuell daraufhin geprüft, ob und in welcher Form sie die aktuelle

Zielrelation zwischen Pakistan und Islamabad ausdrücken. Hierfür wurden fünf Kategorien verwendet:

- **explicit_direct**: Die Relation wird in direkter Richtung von Pakistan zu Islamabad ausgedrückt.
- **explicit_inverse**: Die Relation wird ausgehend von Islamabad in inverser sprachlicher Richtung ausgedrückt.
- **explicit_other**: Die aktuelle Relation wird anderweitig eindeutig ausgedrückt, ohne unmittelbar einer der beiden zuvor genannten Formulierungsformen zu entsprechen.
- **historical**: Das Fenster enthält historische Angaben zu früheren oder vorläufigen Hauptstädten und wurde deshalb nicht als Evidenz für die aktuelle Zielrelation verwendet.
- **false_positive**: Die Suchbegriffe treten zwar gemeinsam im Trainingsfenster auf, drücken die gesuchte Relation jedoch nicht aus.

Tabelle 5 zeigt die Verteilung der manuellen Klassifikation sowie jeweils ein beispielhaftes Kandidatenfenster.

Tabelle 5. Ergebnisse der manuellen Klassifikation der Kandidatenfenster

Kategorie	Anzahl	Beispiel-ID	Beispielhafte Formulierung
explicit_direct	3	873	„The capital of Pakistan is Islamabad“
explicit_inverse	8	3807	„Islamabad [...] is the Federal capital city of Pakistan“
explicit_other	5	37114	„Pakistan’s capital Islamabad“
historical	3	9164	„It was the capital of Pakistan 1947–59, when it was replaced by Islamabad.“
false_positive	16	34438	„Islamabad, Capital Territory, Pakistan“
Gesamt	35		

Finale Evidenzmenge Von den 35 automatisch identifizierten Kandidaten wurden 16 Fenster als Evidenz für die aktuelle Zielrelation eingestuft. Davon enthielten drei eine direkte, acht eine inverse und fünf eine sonstige explizite Formulierung der Relation. Drei weitere Kandidaten beschrieben historische Konstellationen und wurden ausgeschlossen; bei 16 Fenstern handelte es sich um False Positives des automatischen Filters.

Die finale Evidenzmenge E_F umfasst 16 ausgewählte Evidenzstellen, die jeweils einem Trainingsfenster zugeordnet sind. Die Menge dieser 16 Trainingsfenster wird als W_F bezeichnet. Eine vollständige Auflistung der klassifizierten Evidenzstellen mit Window-ID und Textausschnitt befindet sich in Anhang C.

Die Auswahl umfasst damit die anhand der beschriebenen Suchheuristik identifizierten relationstragenden Trainingsbelege. Die Heuristik kann insbesondere anders formulierte, indirekte oder redundante Evidenzstellen übersehen, wenn diese nicht alle verwendeten Suchbegriffe enthalten. E_F wird daher nicht als vollständige Menge sämtlicher Trainingsinformation zur Zielrelation interpretiert.

5.5 Gradient-Ascent-Varianten

Für beide Gradient-Ascent-Varianten wurde eine gemeinsame Konfiguration für das Unlearning verwendet. Die Unlearning-Läufe wurden auf maximal 16 Optimierungsschritte begrenzt und nach den Schritten 0, 1, 2, 5, 10 und 16 evaluiert. Die Batchgröße betrug 1, Weight Decay wurde deaktiviert und die Gradientennorm auf 1,0 begrenzt. Untersucht wurden die Lernraten 1×10^{-6} , 5×10^{-6} , 1×10^{-5} , $1,5 \times 10^{-5}$, 2×10^{-5} und 3×10^{-5} .

Die Wahl der Lernrate erfolgte explorativ. Ausgehend von kleinen Lernraten wurde sie in aufeinanderfolgenden Versuchsläufen schrittweise erhöht, um zu untersuchen, ab welcher Lernrate eine messbare Schwächung der Zielrelation auftritt und wie sich gleichzeitig die Modell-Utility verändert. Es wurde somit kein vorab festgelegtes Optimierungsverfahren zur Bestimmung einer optimalen Lernrate eingesetzt. Die untersuchten Lernraten dienen vielmehr als Sensitivitätsanalyse für den Zusammenhang zwischen Zielschwächung und Kollateraleffekten.

Die Auswertung der einzelnen Läufe erfolgt anhand der Zielrelation, des Validierungsverlusts und der Kontrollfakten. Dadurch können sowohl die Entwicklung der Zielschwächung als auch die begleitenden Kollateraleffekte und Veränderungen der Modell-Utility untersucht werden.

Sequenzweiter Forget-Loss Beim sequenzweiten Gradient Ascent wird der in Abschnitt 2 beschriebene Sprachmodell-Loss über sämtliche Tokenpositionen der ausgewählten Forget-Sequenzen berechnet und maximiert. Somit tragen alle Zielpositionen eines 1024-Token-Trainingsfensters zum Forget-Loss bei.

Token-selektiver Forget-Loss Bei der zweiten Gradient-Ascent-Variante bleibt die vollständige Forget-Sequenz als Modelleingabe erhalten, der Forget-Loss wird jedoch nur für ausgewählte Tokenpositionen berechnet. Für jede Sequenz wird hierzu manuell eine *Zielposition* annotiert, deren vorherzusagendes Token zusammen mit dem vorausgehenden Kontext die untersuchte Relation möglichst unmittelbar ausdrückt.

Welche Zielposition ausgewählt wird, hängt von der sprachlichen Form der jeweiligen Evidenzstelle ab. Bei einer direkten Formulierung wie „The capital of Pakistan is Islamabad“ wird beispielsweise die Position des Zieltokens „Islamabad“ verwendet. Bei einer inversen Formulierung wie „Islamabad, the capital of Pakistan“ wird dagegen die Position des Zieltokens „Pakistan“ ausgewählt. Bei abweichenden Formulierungen wird diejenige Position annotiert, deren Zieltoken die Relation im jeweiligen vorausgehenden Kontext am unmittelbarsten ausdrückt. Für jedes Evidenzfenster wurde genau eine Zielposition annotiert.

Für eine Forget-Sequenz $w \in W_F$ bezeichnet S_w die Menge der annotierten Zielpositionen. Der token-selektive Forget-Loss für diese Sequenz wird als

$$\mathcal{L}_{F,w}^{\text{tok}} = -\frac{1}{|S_w|} \sum_{t \in S_w} \log p_{\theta}(x_t \mid x_{<t}) \quad (6)$$

berechnet. Dabei enthält S_w ausschließlich die Positionen, deren tokenweiser Loss in die Berechnung eingeht. Da für jedes Evidenzfenster genau eine Zielposition annotiert wurde, enthält S_w in der vorliegenden Untersuchung jeweils genau ein Element. Die allgemeine Formulierung erlaubt jedoch auch mehrere Zielpositionen pro Sequenz. Die übrigen Positionen tragen nicht zum Forget-Loss bei. Die vollständige Sequenz bleibt jedoch als Modelleingabe erhalten, sodass für jede ausgewählte Zielposition weiterhin alle kausal vorangehenden Token als Kontext zur Verfügung stehen, wie in 6 dargestellt:

Tabelle 6. Beispiele annotierter Zielpositionen für den token-selektiven Forget-Loss

Window-ID	Form	Evidenzausschnitt	Zieltoken
873	direkt	„The capital of Pakistan is Islamabad“	„Islamabad“
3807	invers	„Islamabad [...] is the Federal capital city of Pakistan“	„Pakistan“
28362	anaphorisch	„the Pakistani capital“	„capital“
37114	sonstig	„Pakistan’s capital Islamabad“	„Islamabad“

In der finalen Evidenzmenge wurde achtmal das Token „Islamabad“, siebenmal das Token „Pakistan“ und in einem anaphorisch formulierten Fall das Token „capital“ als Zieltoken ausgewählt. Die vollständigen Annotationen der Zielpositionen sind in Anhang E dokumentiert.

5.6 Konstruktion des Referenzkorpus und Referenzmodells

Als empirischer Vergleichszustand wird zusätzlich ein Referenzmodell M_{ref} von Grund auf auf einem modifizierten Trainingskorpus trainiert. Im Unterschied zum Basismodell enthält dieser Korpus die im Rahmen der Korpusanalyse identifizierten expliziten Trainingsbelege der Zielrelation nicht. Dadurch kann das Verhalten der Unlearning-Modelle mit einem Modell verglichen werden, das diese ausgewählten Belege nicht im Training gesehen hat.

Für jedes der 16 Evidenzfenster wurde hierzu manuell ein möglichst kleiner zusammenhängender *Löschspan* festgelegt, der die Relation zwischen Pakistan und Islamabad explizit ausdrückt. Es wurde bewusst nicht das gesamte 1024-Token-Fenster entfernt, da dadurch zusätzlich eine große Menge nicht adressierter Trainingsinformation verloren gehen würde. Da die Zielrelation im Korpus in unterschiedlichen sprachlichen Formen auftritt, wurde für jedes Evidenzfenster ein

individueller Löschespan festgelegt. Tabelle 7 zeigt exemplarisch drei unterschiedliche Formen der lokalen Entfernung. Es wurden keine Ersatzformulierungen oder neuen inhaltlichen Textbestandteile eingefügt.

Tabelle 7. Beispiele für Löschespans unterschiedlicher sprachlicher Formen der Zielrelation

Form	Window- ID	Löschspan
invers	9469	„, the capital city of Pakistan“
direkt	9223	„Pakistan’s capital city of“
anaphorisch	28362	„Being the main airport for the Pakistani capital“

Zur eindeutigen technischen Lokalisierung wurde jedem Löschespan ein längerer *Textanker* im ursprünglichen Rohkorpus zugeordnet. Die Implementierung prüft, dass sowohl der Textanker als auch der darin enthaltene Löschespan eindeutig aufgelöst werden können, bevor die entsprechende Zeichenfolge entfernt wird. Eine vollständige Übersicht der 16 Löschespans ist in Anhang B dokumentiert.

Für das Training von M_{ref} wurden Modellarchitektur, Tokenisierung, Trainingskonfiguration und Trainingsbudget soweit wie möglich an das Basismodell M_0 angeglichen. Die Löschungen wurden ausschließlich im Trainingssplit vorgenommen, sodass beide Modelle auf denselben Validierungsdaten evaluiert werden.

M_{ref} ist dennoch nicht als Modell zu interpretieren, dessen Trainingskorpus keinerlei Evidenz zur Zielrelation enthält. Entfernt wurden ausschließlich die identifizierten expliziten Trainingsbelege; indirekte, redundante oder anders formulierte Hinweise können im verbleibenden Korpus weiterhin vorhanden sein. Darüber hinaus stand der ursprüngliche Initialisierungszustand von M_0 für das Referenztraining nicht mehr zur Verfügung, sodass trotz gleicher Architektur, vergleichbarer Trainingskonfiguration und desselben Zufalls-Seeds keine bit-identische Ausgangsinitialisierung gewährleistet werden konnte. Auch stochastische Unterschiede des Trainingsverlaufs können zu Abweichungen beitragen. M_{ref} wird deshalb als empirischer Referenzzustand für das Training auf dem modifizierten Korpus und nicht als kausal kontrolliertes oder exaktes Retraining von M_0 interpretiert.

Damit sind die experimentellen Modellzustände sowie die Erzeugung der beiden Unlearning-Varianten und des Referenzmodells festgelegt. Das folgende Kapitel definiert anhand welcher Messgrößen und Kontrollgruppen diese Zustände im Hinblick auf die drei Forschungsfragen verglichen werden.

6 Evaluationsstrategie

Die Evaluation untersucht die durch das Unlearning erzeugten Modellveränderungen anhand mehrerer komplementärer Perspektiven. Im Mittelpunkt stehen

die Schwächung der Zielrelation, die Selektivität der Modelländerung und der Vergleich mit dem neu trainierten Referenzmodell.

Da das Basismodell nicht für Frage-Antwort-Aufgaben feinabgestimmt wurde, erfolgt die quantitative Bewertung primär anhand der vom Modell zugewiesenen Token- und Sequenzwahrscheinlichkeiten. Hierzu werden zunächst die verwendeten Evaluationsdaten beschrieben und anschließend die zentralen Messgrößen definiert. Darauf aufbauend wird festgelegt, wie diese Größen zur Beantwortung der drei Forschungsfragen eingesetzt werden.

6.1 Evaluationsdaten

Zielprompts und Counterfactuals Die Zielrelation `capital(Pakistan, Islamabad)` wird anhand von fünf festgelegten Zielprompts in beiden Relationsrichtungen untersucht. Drei Prompts adressieren die Relation von Pakistan zu Islamabad, zwei weitere die inverse Richtung von Islamabad zu Pakistan. Dabei werden unterschiedliche sprachliche Formulierungen berücksichtigt.

Für jeden Zielprompt werden neben der korrekten Zielsequenz zusätzlich drei kontrollierte, faktisch falsche Alternativsequenzen ausgewertet. Diese werden im Folgenden als *Counterfactuals* bezeichnet. Sie dienen dazu zu untersuchen, ob sich eine durch das Unlearning verursachte Wahrscheinlichkeitsänderung vorwiegend auf die korrekte Zielzuordnung konzentriert oder auch alternative Fortsetzungen in vergleichbarer Weise betrifft. Ein Beispiel für die Zielrelation wäre die „Ersetzung“ von Islamabad durch eine andere pakistanische Stadt.

Kontrollfakten Zur Untersuchung möglicher Kollateraleffekte werden Kontrollfakten mit unterschiedlichen Beziehungen zur Zielrelation verwendet. `same_subject` umfasst anderes Faktenwissen über Pakistan, `same_object` anderes Wissen über Islamabad und `same_relation` Hauptstadtbeziehungen anderer Länder. Die Kategorie `same_window` enthält Fakten, die gemeinsam mit einer Forget-Evidenzstelle im selben Trainingsfenster vorkommen und bildet damit eine trainingskontextuelle Nähe ab. `unrelated` umfasst schließlich Fakten ohne gezielt gewählte semantische, relationale oder trainingskontextuelle Beziehung zur Zielrelation.

Die Kategorien operationalisieren unterschiedliche Formen der Nähe zur Zielrelation, stellen jedoch keine mathematische Distanzskala dar. `same_subject`, `same_object` und `same_relation` erfassen semantische beziehungsweise relationale Beziehungen, während `same_window` eine trainingskontextuelle Beziehung auf Grundlage des tatsächlich verwendeten Trainingskorpus abbildet.

So weist beispielsweise der in Tabelle 8 gezeigte Fakt über Robert Urich keine gezielte inhaltliche Beziehung zur Zielrelation auf, trat jedoch im Trainingskorpus im selben Fenster wie eine Forget-Evidenzstelle auf.

Eine vollständige Auflistung der verwendeten Evaluationsprompts und Zielsequenzen einschließlich ihrer Gruppenzuordnung befindet sich in Anhang D.

Validierungsdaten Zur Bewertung der allgemeinen Sprachmodellleistung wird der unveränderte Validierungssplit des Wikipedia-Korpus verwendet. Während

Tabelle 8. Struktur der Ziel- und Kontrollfakten

Gruppe	untersuchte Beziehung	Beispiel	Ziel
<code>target</code>	Zielrelation	„The capital of Pakistan is“	Islamabad
<code>same_subject</code>	anderes Wissen über Pakistan	„Pakistan became independent in“	1947
<code>same_object</code>	anderes Wissen über Islamabad	„Islamabad is a city in“	Pakistan
<code>same_relation</code>	andere Hauptstadtbeziehungen	„The capital of Sweden is“	Stockholm
<code>same_window</code>	gemeinsamer Trainingskontext	„Robert Urich was an Emmy-winning“	actor
<code>unrelated</code>	keine gezielte Nähe	„Bob Ross was an“	American

der Unlearning-Läufe wird der Validierungsverlust auf einem festen Ausschnitt von 50 Batches bestimmt, um Veränderungen zwischen den einzelnen Evaluationschritten zu beobachten.

Für die abschließende Bewertung ausgewählter Modellzustände wird zusätzlich der vollständige Validierungssplit mit 4 161 Validierungsfenstern ausgewertet. Dies entspricht insgesamt 4 260 864 vorhergesagten Target-Tokenpositionen. Die abschließenden Aussagen zur Modell-Utility basieren auf dieser vollständigen Validierungsauswertung.

6.2 Zentrale Evaluationsgrößen

NLL und Target- Δ NLL Für faktische Zielsequenzen wird die vom jeweiligen Modell zugewiesene *Negative Log-Likelihood* (NLL) verwendet. Für einen Prompt x mit der erwarteten Zielsequenz $y = (y_1, \dots, y_m)$ wird sie als

$$\text{NLL}_M(y \mid x) = -\frac{1}{m} \sum_{t=1}^m \log p_M(y_t \mid x, y_{<t}) \quad (7)$$

berechnet, wobei m die Anzahl der Token der Zielsequenz bezeichnet.

Für einen Evaluationsprompt $p = (x_p, y_p)$ wird die Veränderung gegenüber dem Basismodell M_0 als

$$\Delta \text{NLL}_p(M) = \text{NLL}_M(y_p \mid x_p) - \text{NLL}_{M_0}(y_p \mid x_p) \quad (8)$$

definiert. Ein positiver Wert bedeutet, dass die erwartete Zielsequenz unter dem betrachteten Modell gegenüber M_0 unwahrscheinlicher geworden ist. Ein Wert nahe null zeigt nur eine geringe Veränderung, während ein negativer Wert auf eine höhere Wahrscheinlichkeit der Zielsequenz hinweist.

Für die fünf Zielprompts wird die mittlere Veränderung als Target- Δ NLL zusammengefasst. Ergänzend werden Rang und Wahrscheinlichkeit des jeweils ersten erwarteten Zieltokens betrachtet.

Counterfactual- Δ NLL Für die kontrollierten falschen Alternativtargets wird dieselbe NLL-basierte Auswertung wie für die korrekten Zielsequenzen durchgeführt. Die Veränderung gegenüber M_0 wird für die Counterfactuals separat bestimmt und anschließend als mittlere Counterfactual- Δ NLL zusammengefasst.

Eine deutlich stärkere NLL-Zunahme der korrekten Zielsequenzen als der Counterfactuals wird als Hinweis darauf interpretiert, dass sich die Modelländerung stärker auf die untersuchte Zielzuordnung konzentriert. Die Counterfactual-Auswertung ist dabei deskriptiv und wird nicht als allgemeines Maß für Kollateraleffekte auf andere faktische Informationen verstanden.

Tokenbezogene Verluste innerhalb der Forget-Sequenzen Da sich die beiden Gradient-Ascent-Varianten darin unterscheiden, welche Tokenpositionen zum Forget-Loss beitragen, werden Veränderungen innerhalb der 16 Forget-Sequenzen zusätzlich auf Tokenebene untersucht.

Die Tokenpositionen werden anhand der für das token-selektive Unlearning definierten Annotationen in zwei Mengen unterteilt. Die Menge R (Relationstragend) enthält die relationstragenden Zielpositionen, während C (Context) alle übrigen vorherzusagenden Positionen derselben Forget-Sequenzen umfasst. Für einen Modellzustand M werden die mittleren Verluste

$$L_{\text{rel}}(M) = \frac{1}{|R|} \sum_{t \in R} -\log p_M(x_t \mid x_{<t}) \quad (9)$$

und

$$L_{\text{ctx}}(M) = \frac{1}{|C|} \sum_{t \in C} -\log p_M(x_t \mid x_{<t}) \quad (10)$$

bestimmt. Die Veränderungen gegenüber dem Basismodell werden als ΔL_{rel} beziehungsweise ΔL_{ctx} angegeben.

Ein positiver Wert von ΔL_{rel} zeigt, dass die annotierten Zielpositionen gegenüber M_0 schlechter vorhergesagt werden. ΔL_{ctx} erfasst dagegen Veränderungen an den nicht gezielt ausgewählten Positionen derselben Forget-Sequenzen.

Veränderungen der Kontrollfakten Für die Kontrollfakten wird ebenfalls die Veränderung der NLL gegenüber dem Basismodell ausgewertet. Da einzelne Fakten durch unterschiedlich viele Promptvarianten (z. B. direkte, inverse oder paraphrasierte Formulierungen) repräsentiert werden, erfolgt die Aggregation zweistufig. Zunächst wird für jeden Fakt die mittlere Δ NLL über seine Promptvarianten bestimmt. Anschließend wird innerhalb jeder Kontrollgruppe (z. B. `same_subject`, `same_relation` oder `same_window`) der Mittelwert über die enthaltenen Fakten gebildet.

Dadurch erhalten Fakten mit mehreren Promptvarianten innerhalb einer Gruppe kein höheres Gewicht als Fakten mit nur einer Formulierung. Die resultierenden Gruppenwerte zeigen, wie stark sich unterschiedlich zur Zielrelation stehende faktische Informationen gegenüber M_0 verändern.

Modell-Utility Als Modell-Utility wird in dieser Arbeit der Erhalt der allgemeinen Sprachmodelleleistung auf dem unveränderten Validierungsdatensatz bezeichnet. Als Metrik dient der vollständige Sprachmodell-Loss $L_{\text{val}}(M)$.

Die Veränderung gegenüber dem Basismodell wird als

$$\Delta L_{\text{val}}(M) = L_{\text{val}}(M) - L_{\text{val}}(M_0) \quad (11)$$

berechnet. Ein Wert nahe null bedeutet, dass sich die Sprachmodelleleistung auf dem Validierungsdatensatz gegenüber M_0 nur gering verändert hat. Positive Werte zeigen eine Erhöhung des Validierungsverlusts und damit eine Verschlechterung der Next-Token-Prediction an.

Ergänzend wird die Perplexity verwendet, um die Größenordnung der Veränderung anschaulicher darzustellen. Da sie unmittelbar aus dem Sprachmodell-Loss abgeleitet wird, stellt sie keine unabhängige Evaluationsgröße dar.

6.3 Auswertung nach Forschungsfragen

Die zuvor definierten Evaluationsgrößen werden zur Beantwortung der drei Teilfragen in unterschiedlichen Vergleichssituationen kombiniert. Tabelle 9 fasst diese Zuordnung zusammen.

Tabelle 9. Zuordnung der Evaluationsbestandteile zu den Forschungsfragen

Frage Vergleich		Primäre Bewertung	Ergänzende Bewertung
1	gleiche Optimierungsbedingungen	Target- Δ NLL	Relationsrichtung und Tokenrang
2	vergleichbare Zielschwächung	ΔL_{ctx} und Kontrollfakten	Counterfactuals und ΔL_{val}
3	Unlearning-Zustände gegenüber M_{ref}	Zielrelation und Kontrollfakten	Modell-Utility

Erste Forschungsfrage: Schwächung der Zielrelation Die erste Teilfrage untersucht, wie stark die beiden Forget-Loss-Varianten die Zielrelation unter identischen Optimierungsbedingungen schwächen. Als primäre Größe dient die mittlere Target- Δ NLL der fünf Zielprompts. Ergänzend werden die direkte und inverse Relationsrichtung sowie Rang und Wahrscheinlichkeit des jeweils ersten erwarteten Zieltokens betrachtet. Die untersuchten Lernraten dienen dabei als Sensitivitätsanalyse und zeigen, wie sich die Zielschwächung mit zunehmender Lernrate verändert.

Zweite Forschungsfrage: Selektivität und Kollateraleffekte Die zweite Teilfrage untersucht, wie selektiv die beiden Forget-Loss-Varianten bei vergleichbarer Schwächung der Zielrelation wirken. Da identische Lernraten aufgrund der unterschiedlichen Loss-Definitionen nicht zu einer vergleichbaren Target- ΔNLL führen müssen, wird hierfür zusätzlich ein Matched-Forgetting-Vergleich durchgeführt.

Vergleich bei ähnlicher Zielschwächung Der im Folgenden als *Matched-Forgetting* bezeichnete Vergleich stellt die evaluierten Modellzustände beider Varianten anhand ihrer mittleren Target- ΔNLL gegenüber. Für den direkten Vergleich wird das Paar mit der geringsten relativen Abweichung dieser Größe ausgewählt. Metriken zur Modell-Utility oder zu Kollateraleffekten gehen nicht in die Auswahl ein, sondern werden erst anschließend verglichen. Dadurch wird vermieden, einen Modellzustand aufgrund bereits bekannter günstiger Kollateraleffekte auszuwählen.

Selektivität innerhalb der Forget-Sequenzen Zunächst wird anhand von ΔL_{rel} und ΔL_{ctx} untersucht, ob die Loss-Zunahme innerhalb der Forget-Sequenzen überwiegend an den annotierten Zielpositionen auftritt oder auch die übrigen Positionen derselben Sequenzen betrifft.

Counterfactuals Anschließend wird die Target- ΔNLL der korrekten Zielsequenzen der Counterfactual- ΔNLL gegenübergestellt. Dadurch wird geprüft, ob sich die Veränderung innerhalb derselben Zielprompts stärker auf die korrekte faktische Zuordnung konzentriert als auf kontrollierte falsche Alternativsequenzen.

Kollateraleffekte auf Kontrollfakten Darüber hinaus wird untersucht, wie sich die Modelländerung auf die in Tabelle 8 definierten Kontrollgruppen auswirkt. Dadurch werden mögliche Kollateraleffekte auf semantisch, relational oder trainingskontextuell zur Zielrelation stehende sowie unabhängige Fakten erfasst.

Modell-Utility Schließlich wird anhand von ΔL_{val} geprüft, ob die beiden Varianten bei vergleichbarer Zielschwächung unterschiedlich starke Veränderungen der allgemeinen Sprachmodellleistung verursachen.

Dritte Forschungsfrage: Vergleich mit dem Referenzmodell Für das Referenzmodell M_{ref} werden dieselben zentralen Evaluationsgrößen wie für M_0 und die durch Unlearning erzeugten Modellzustände bestimmt. Dadurch können die Modelle hinsichtlich der Zielrelation, der Kontrollfakten und der Modell-Utility deskriptiv miteinander verglichen werden.

Der Vergleich dient der empirischen Einordnung der durch Unlearning erzeugten Modellzustände. Er stellt keine formale Prüfung einer Übereinstimmung von Modellverteilungen im Sinne von Exact Unlearning oder formal garantiertem Approximate Unlearning dar.

7 Ergebnisse

Dieses Kapitel berichtet die Ergebnisse des in Kapitel 5 beschriebenen Versuchsaufbaus anhand der in Kapitel 6 festgelegten Evaluationsgrößen. Nach dem Ausgangszustand des Basismodells werden die Befunde entlang der drei Forschungsfragen dargestellt: zunächst die Schwächung der Zielrelation, anschließend die Selektivität und Kollateraleffekte bei vergleichbarer Zielschwächung und abschließend die Einordnung gegenüber dem Referenzmodell.

7.1 Ausgangszustand des Basismodells

Ausgangspunkt sämtlicher Unlearning-Läufe ist das Basismodell M_0 bei Trainingsschritt 46 460. Vor Anwendung des Unlearnings wurde die Zielrelation mit den fünf in der Evaluationsstrategie festgelegten Zielprompts ausgewertet. Die drei direkten Prompts adressieren die Relation von Pakistan zu Islamabad, während zwei weitere Prompts die inverse Richtung von Islamabad zu Pakistan prüfen.

Tabelle 10 zeigt den Ausgangszustand getrennt nach Relationsrichtung. Die korrekte Zielantwort erreicht bei den direkten Prompts eine mittlere NLL von 2,0955 und einen medianen First-Token-Rang von 1. Bei den inversen Prompts beträgt die mittlere NLL 2,3808 bei einem medianen Rang von 2. Über alle fünf Zielprompts ergibt sich eine mittlere NLL von 2,2096.

Tabelle 10. Ausgangszustand des Basismodells auf der Zielrelation

Richtung	Prompts	mittl. NLL	mittl. Zielwahrsch.	Median Rang
direkt	3	2,0955	0,1636	1
invers	2	2,3808	0,1009	2

Der vollständige Validierungsverlust von M_0 beträgt 3,110449 bei einer Perplexity von 22,4311. Dieser Wert bildet im Folgenden den Bezugspunkt für die abschließende Bewertung der Modell-Utility.

7.2 Erste Forschungsfrage – Einfluss der Loss-Granularität auf die Zielschwächung

Einfluss der Eingriffsstärke Für beide Gradient-Ascent-Varianten wurden sechs Lernraten zwischen 1×10^{-6} und 3×10^{-5} untersucht. Jeder Lauf beginnt erneut bei M_0 und umfasst 16 Gradient-Ascent-Updates, sodass jedes der 16 Forget-Fenster innerhalb eines vollständigen Durchlaufs einmal für ein Update verwendet wird.

Abbildung 1 zeigt die mittlere Veränderung der NLL der fünf Zielprompts nach dem vollständigen Durchlauf. Bei beiden Varianten nimmt die Zielschwächung mit steigender Lernrate zu. Der token-selektive Forget-Loss schwächt die Zielrelation jedoch bei jeder untersuchten Lernrate deutlich stärker als der sequenzweite Forget-Loss.




Abb. 1. Mittlere Veränderung der NLL der Zielrelation nach 16 Unlearning-Schritten in Abhängigkeit von der Lernrate

Tabelle 11 zeigt die zugrunde liegenden Werte. Bei einer Lernrate von 1×10^{-5} beträgt die mittlere ΔNLL beim Full-Sequence GA 0,2572 und beim token-selektiven GA 3,7644. Bei der höchsten untersuchten Lernrate von 3×10^{-5} steigen die Werte auf 1,3809 beziehungsweise 12,7971.

Tabelle 11. Target- ΔNLL nach 16 Updates in Abhängigkeit von der Lernrate

Lernrate	Full-Sequence ΔNLL	Token-selektiv ΔNLL
1×10^{-6}	0,0215	0,3199
5×10^{-6}	0,1158	1,7582
1×10^{-5}	0,2572	3,7644
$1,5 \times 10^{-5}$	0,4343	5,8872
2×10^{-5}	0,6626	8,0887
3×10^{-5}	1,3809	12,7971

Der Effekt tritt dabei nicht ausschließlich in einer Relationsrichtung auf. Bei 1×10^{-5} beträgt die Δ NLL des Full-Sequence GA für die direkten Zielprompts 0,2753 und für die inversen Prompts 0,2300. Beim token-selektiven GA ergeben sich 3,5809 beziehungsweise 4,0396. Auch bei der höchsten Lernrate werden sowohl die direkte als auch die inverse Relationsrichtung deutlich geschwächt.

Bei der Interpretation des Vergleichs bei identischer Lernrate ist zusätzlich das verwendete Gradient Clipping zu berücksichtigen. Bei sämtlichen Unlearning-Updates überschreitet die ungeclippte Gradientennorm die festgelegte Clipping-Grenze von 1,0. Der Median der ungeclippten Gradientennorm über die untersuchten Läufe betrug beim Full-Sequence GA ungefähr 1,51, beim token-selektiven GA dagegen ungefähr 63,57. Die unterschiedlichen Forget-Loss-Definitionen erzeugten somit deutlich unterschiedlich skalierte Rohgradienten, deren Norm vor dem Optimierungsschritt jeweils auf denselben Maximalwert begrenzt wurde.

Die Verwendung identischer Lernraten und derselben Gradient-Clipping-Grenze entspricht daher gleichen Optimierungshyperparametern, nicht jedoch identischen Gradienten oder Parameteränderungen.

Die Sensitivitätsanalyse zeigt damit, dass die Zielrelation sowohl in Abhängigkeit von der Lernrate als auch von der verwendeten Forget-Loss-Definition unterschiedlich stark geschwächt wird. Ein Vergleich bei gleicher Lernrate entspricht jedoch nicht einem Vergleich bei gleicher tatsächlich erreichter Zielschwächung. Die in Abbildung 1 und Tabelle 11 dargestellten Werte beziehen sich ausschließlich auf die Modellzustände nach 16 Unlearning-Schritten. Während der Läufe wurden jedoch zusätzlich die Zwischenzustände nach 1, 2, 5 und 10 Schritten evaluiert. Diese Zwischenzustände werden im folgenden Matched-Forgetting-Vergleich berücksichtigt, um Zustände beider Varianten mit möglichst ähnlicher Zielschwächung zu identifizieren.

7.3 Zweite Forschungsfrage – Selektivität und Kollateraleffekte

Vergleich bei vergleichbarer Zielschwächung Der Vergleich bei gleicher Lernrate zeigt, wie sich die beiden Loss-Varianten unter denselben Optimierungsbedingungen verhalten. Da die beiden Varianten nach einem vollständigen Durchlauf keine vergleichbare Zielschwächung aufweisen, werden für den Matched-Forgetting-Vergleich zusätzlich die evaluierten Zwischenzustände der Unlearning-Läufe herangezogen. Hierzu werden die nicht-baseline Modellzustände beider Varianten über die untersuchten Lernraten und Evaluationsschritte anhand ihrer Target- Δ NLL miteinander verglichen.

Das ähnlichste Paar ergibt sich, wie in Tabelle 12 dargestellt, für den Full-Sequence GA bei einer Lernrate von 2×10^{-5} nach fünf Updates und für den token-selektiven GA bei 1×10^{-6} nach zehn Updates. Die Target- Δ NLL beträgt für diese Zustände 0,20355 beziehungsweise 0,20438 und unterscheidet sich damit nur um etwa 0,41 %.

Tabelle 12. Vergleich der beiden Gradient-Ascent-Varianten bei vergleichbarer Zielschwächung

Metrik	Full-Sequence	Token-selektiv
Lernrate	2×10^{-5}	1×10^{-6}
Unlearning-Schritt	5	10
Target- Δ NLL	0,20355	0,20438
ΔL_{ctx}	0,04030	0,00021
Counterfactual- Δ NLL	0,00791	0,02312
ΔL_{val}	0,00216	-0,00016
Perplexity-Änderung	+0,216 %	-0,016 %

Die beiden ausgewählten Modellzustände weisen mit 0,20355 beziehungsweise 0,20438 eine nahezu identische Target- Δ NLL auf. Sie bilden daher im Folgenden die Grundlage für den direkten Vergleich der Selektivität und Kollateraleffekte bei vergleichbarer Zielschwächung.

Tokenbezogene Selektivität innerhalb der Forget-Sequenzen Wie in der Evaluationsstrategie beschrieben, werden die 16 relationstragenden Zielpositionen getrennt von den übrigen 16 368 vorherzusagenden Positionen der Forget-Sequenzen ausgewertet. Dadurch lässt sich untersuchen, ob sich die Modelländerung stärker auf die annotierten Zielpositionen konzentriert oder auch die übrigen Positionen derselben Sequenzen betrifft.

Im Matched-Forgetting-Vergleich zeigt sich hier der deutlichste Unterschied zwischen den beiden Varianten. Beim Full-Sequence GA beträgt $\Delta L_{\text{ctx}} = 0,04030$, während der Wert beim token-selektiven Zustand mit 0,00021 nahezu bei null liegt. Bei nahezu identischer Target- Δ NLL verändert der token-selektive Zustand die nicht relationstragenden Positionen der Forget-Sequenzen damit wesentlich weniger.

Abbildung 2 stellt ΔL_{rel} und ΔL_{ctx} für beide Varianten über die untersuchten Lernraten gegenüber.

Beim Full-Sequence GA steigen beide Größen mit zunehmender Lernrate. Bei 1×10^{-5} beträgt $\Delta L_{\text{rel}} = 0,2643$ und $\Delta L_{\text{ctx}} = 0,0701$. Bei 3×10^{-5} steigen die Werte auf 1,9118 beziehungsweise 0,4641.

Beim token-selektiven GA ist die Differenz zwischen beiden Positionsmengen wesentlich größer. Bereits bei 1×10^{-6} beträgt $\Delta L_{\text{rel}} = 0,3970$, während ΔL_{ctx} mit 0,00035 nahezu unverändert bleibt. Bei 1×10^{-5} ergeben sich 5,9160 beziehungsweise 0,0264 und bei 3×10^{-5} 19,4842 beziehungsweise 0,3071.

Die tokenbezogene Auswertung zeigt damit sowohl im Matched-Forgetting-Vergleich als auch über den untersuchten Lernratenbereich eine stärkere Konzentration der Modelländerung auf die annotierten relationstragenden Positionen beim token-selektiven Forget-Loss. Dieser Befund beschreibt jedoch zunächst eine tokenbezogene Selektivität innerhalb der bearbeiteten Forget-Sequenzen. Ob sich




Abb. 2. Veränderung der relationstragenden Tokenpositionen in Abhängigkeit von der Veränderung des übrigen Sequenzkontexts. Die Beschriftungen geben die jeweilige Lernrate an.

diese auch auf andere Formen von Selektivität überträgt, wird in den folgenden Auswertungen separat untersucht.

Counterfactual-Auswertung Als nächste Ebene wird untersucht, ob sich die Modelländerung innerhalb der Zielprompts stärker auf die korrekten Zielsequenzen als auf die kontrollierten falschen Alternativtargets konzentriert.

Im Matched-Forgetting-Paar beträgt die mittlere Counterfactual- ΔNLL beim Full-Sequence-Zustand 0,00791 und beim token-selektiven Zustand 0,02312. Obwohl die Target- ΔNLL beider Zustände nahezu identisch ist, werden die ausgewählten falschen Alternativtargets beim token-selektiven Zustand damit etwas stärker verändert. Über die Modellzustände nach 16 Updates zeigt sich zunächst, dass die korrekten Zielsequenzen bei allen untersuchten Lernraten stärker verändert werden als die betrachteten falschen Alternativtargets.

Bei einer Lernrate von 3×10^{-5} beträgt die mittlere Target- ΔNLL beim Full-Sequence GA 1,3809, während die mittlere Counterfactual- ΔNLL 0,1931 beträgt. Beim token-selektiven GA ergeben sich für dieselbe Lernrate Werte von 12,7971 beziehungsweise 3,1113.

Die Veränderung beschränkt sich damit nicht vollständig auf die korrekten Zielsequenzen, fällt für diese jedoch in allen untersuchten Modellzuständen stärker aus als für die ausgewählten falschen Alternativtargets.

Kollateraleffekte auf Kontrollfakten Über alternative Zielsequenzen derselben Zielprompts hinaus wird anschließend untersucht, ob die Modelländerung auf andere faktische Informationen übergreift. Die Kontrollgruppen erfassen hierzu inhaltliche, relationale und trainingskontextuelle Beziehungen zur Zielrelation.

Für diesen Vergleich wird erneut das Matched-Forgetting-Paar aus Tabelle 12 verwendet, sodass die beiden Varianten eine nahezu identische Veränderung der Zielrelation aufweisen. Abbildung 3 visualisiert die Veränderungen der Kontrollgruppen.




Abb. 3. Veränderung der Kontrollfakten bei vergleichbarer Zielschwächung

Für `same_subject`, `same_window` und `unrelated` bleiben die Veränderungen bei beiden Varianten vergleichsweise gering. Die Gruppe `same_object` zeigt dagegen bei beiden Varianten eine größere NLL-Zunahme und ist beim token-selektiven Zustand mit 0,1573 stärker betroffen als beim Full-Sequence-Zustand mit 0,1068.

Ein weiterer Unterschied zeigt sich bei der inversen Richtung der Gruppe `same_relation`. Hier beträgt die ΔNLL beim Full-Sequence GA 0,0187 und beim token-selektiven GA 0,0778. Für die direkte Richtung liegen die Werte mit 0,0270 und 0,0294 dagegen nahe beieinander.

Die geringere Veränderung der nicht relationstragenden Positionen beim token-selektiven Verfahren geht damit nicht in allen Kontrollgruppen mit geringeren faktischen Veränderungen einher. Tokenbezogene Selektivität innerhalb der Forget-Sequenzen und Kollateraleffekte auf andere faktische Informationen bilden somit unterschiedliche Aspekte der Selektivität.

Zielschwächung und Modell-Utility Die bisherigen Auswertungen betrachten Veränderungen innerhalb der Forget-Sequenzen, der Zielprompts und anderer faktischer Informationen. Abschließend wird untersucht, wie sich die Schwächung der Zielrelation zur allgemeinen Modell-Utility verhält. Hierzu wurden sämtliche Step-16-Zustände auf allen 4161 Validierungsfenstern ausgewertet. Abbildung 4 stellt die Target- Δ NLL der Veränderung des vollständigen Validierungsverlusts gegenüber.




Abb. 4. Zusammenhang zwischen Target- Δ NLL und Veränderung des vollständigen Validierungsverlusts nach 16 Unlearning-Schritten

Bei den kleineren Lernraten bleibt die Veränderung des vollständigen Validierungsverlusts für beide Varianten gering. Beim Full-Sequence GA beträgt ΔL_{val} bei 1×10^{-5} 0,0021, was einer Perplexity-Zunahme von ungefähr 0,21 % entspricht. Beim token-selektiven GA beträgt die Veränderung bei derselben Lernrate 0,0085 beziehungsweise ungefähr 0,85 %.

Bei 2×10^{-5} steigt die Perplexity gegenüber M_0 beim Full-Sequence GA um ungefähr 2,50 % und beim token-selektiven GA um 4,97 %. Die stärkste untersuchte Konfiguration mit 3×10^{-5} führt schließlich zu einer Zunahme um 20,94 % beim Full-Sequence GA und 17,08 % beim token-selektiven GA.

Bei gleicher Lernrate weist keine der beiden Loss-Varianten über den gesamten untersuchten Bereich hinweg durchgängig die geringere Veränderung der Modell-Utility auf. Dieser Vergleich berücksichtigt jedoch nicht, dass der token-selektive Forget-Loss bei denselben Lernraten eine wesentlich stärkere Zielschwächung erreicht.

Werden Zielschwächung und Modell-Utility gemeinsam betrachtet, zeigt sich daher ein günstigeres Verhältnis beim token-selektiven Ansatz: Starke Zunahmen

der Target- Δ NLL werden zunächst mit vergleichsweise geringen Veränderungen des Validierungsverlusts erreicht. Dieser Befund wird durch das Matched-Forgetting-Paar ergänzt, bei dem die nahezu identische Zielschwächung des token-selektiven Zustands mit einer geringeren Veränderung des Validierungsverlusts verbunden ist. Bei stärkerer Zielschwächung nimmt jedoch auch beim token-selektiven Ansatz die Beeinträchtigung der Modell-Utility deutlich zu. Die Ergebnisse weisen somit auf einen Zielkonflikt zwischen der Schwächung der Zielrelation und dem Erhalt der allgemeinen Sprachmodelleistung hin. Die vollständigen numerischen Ergebnisse aller Step-16-Zustände sind in Tabelle 16 im Anhang aufgeführt. Der Sensitivitätsvergleich ergänzt damit den Matched-Forgetting-Vergleich um die Entwicklung des Zielkonflikts über den untersuchten Lernratenbereich.

7.4 Dritte Forschungsfrage – Vergleich mit dem Referenzmodell

Verhalten des Referenzmodells auf der Zielrelation Der vollständige Zugriff auf den ursprünglichen Trainingskorpus erlaubt zusätzlich einen Vergleich mit einem neu trainierten Modell, bei dem die 16 festgelegten Löschspans bereits vor dem Training aus dem Korpus entfernt wurden. Das Referenzmodell M_{ref} wurde auf denselben fünf Zielprompts wie M_0 und die Unlearning-Modellzustände ausgewertet. Über alle fünf Prompts steigt die mittlere NLL von 2,2096 bei M_0 auf 3,4429 bei M_{ref} . Dies entspricht einer Δ NLL von 1,2333. Die Veränderung unterscheidet sich deutlich zwischen den beiden Relationsrichtungen. Tabelle 13 zeigt die Ergebnisse.

Tabelle 13. Verhalten des Referenzmodells auf der Zielrelation

Richtung	NLL M_0	NLL M_{ref}	Δ NLL	Median Rang	M_{ref}
direkt	2,0955	4,0448	1,9493		8
invers	2,3808	2,5401	0,1594		2

Die direkte Richtung von Pakistan zu Islamabad wird im Referenzmodell damit wesentlich stärker verändert als die inverse Richtung. Bei den drei direkten Prompts erreicht das erwartete Token „Islamabad“ im Referenzmodell die Ränge 8, 7 und 15. Bei den beiden inversen Prompts bleibt „Pakistan“ jeweils auf Rang 2.

Kontrollfakten und Utility des Referenzmodells Neben der Zielrelation wurde M_{ref} mit denselben Kontrollfakten wie die Unlearning-Modelle evaluiert. Tabelle 14 zeigt die Veränderung der mittleren NLL gegenüber M_0 .

Damit unterscheiden sich neben der Zielrelation auch mehrere Kontrollgruppen vom Ausgangsmodell. Die Veränderungen sind jedoch nicht einheitlich gerichtet. Für `same_subject`, `same_relation` und `unrelated` steigt die mittlere NLL, während sie für `same_object` und `same_window` sinkt.

Tabelle 14. Veränderung der Kontrollgruppen im Referenzmodell gegenüber M_0

Kontrollgruppe	$\Delta\text{NLL } M_{\text{ref}}$
same_subject	0,3937
same_object	-0,4076
same_relation direkt	0,4611
same_relation invers	0,5031
same_window	-0,1291
unrelated	0,6092

Auf dem vollständigen Validierungsdatensatz bleibt die Modell-Utility dagegen nahe am Ausgangsmodell. Der Validierungsverlust beträgt 3,113709 gegenüber 3,110449 bei M_0 . Damit ergibt sich

$$\Delta L_{\text{val}}(M_{\text{ref}}) = 0,003259,$$

was einer Erhöhung der Perplexity um ungefähr 0,33 % entspricht.

Vergleich der Unlearning-Modelle mit dem Referenzmodell Tabelle 15 fasst zentrale beobachtbare Größen für M_0 , das Matched-Forgetting-Paar und das Referenzmodell zusammen. Die Modellzustände besitzen dabei nicht dieselbe Zielschwächung. Die Tabelle dient daher nicht als Ranking, sondern stellt die in der Evaluationsstrategie vorgesehenen Verhaltensgrößen gemeinsam dar.

Tabelle 15. Zusammenfassender Vergleich ausgewählter Modellzustände

Modellzustand	Target- ΔNLL	ΔL_{val}	PPL-Änderung
M_0	0	0	0 %
M_U^{seq} (LR 2×10^{-5} , Schritt 5)	0,2036	0,00216	+0,216 %
M_U^{tok} (LR 1×10^{-6} , Schritt 10)	0,2044	-0,00016	-0,016 %
M_{ref}	1,2333	0,00326	+0,326 %

Das Referenzmodell zeigt somit bei nahezu erhaltener Utility eine deutlichere Veränderung der Zielrelation als die beiden für den Matched-Forgetting-Vergleich verwendeten Modellzustände. Gleichzeitig unterscheidet sich sein Verhalten hinsichtlich der Relationsrichtungen: Die direkte Zielrichtung wird deutlich geschwächt, während die inverse Richtung vergleichsweise nahe am Ausgangszustand bleibt.

Der Vergleich mit M_{ref} liefert damit keinen einzelnen Zielwert, den eine der Gradient-Ascent-Varianten vollständig reproduziert. Stattdessen dient das Referenzmodell entsprechend der in der Methodik festgelegten Rolle als zusätzlicher beobachtbarer Vergleichszustand.

Die drei Befundgruppen werden im folgenden Kapitel entlang der Forschungsfragen eingeordnet und hinsichtlich ihrer Aussagegrenzen diskutiert.

8 Diskussion und Limitationen

Die folgenden Abschnitte ordnen die Ergebnisse entlang der drei Forschungsfragen ein und diskutieren anschließend die Aussagegrenzen des kontrollierten Versuchsaufbaus sowie seine Übertragbarkeit.

8.1 Erste Forschungsfrage – Einfluss der Loss-Granularität auf die Zielschwächung

Die Ergebnisse zeigen für die untersuchte Zielrelation einen deutlichen Einfluss der Loss-Granularität. Bei gleicher nomineller Lernrate führte der token-selektive Forget-Loss über den gesamten untersuchten Lernratenbereich zu einer deutlich stärkeren Erhöhung der NLL der Zielrelation als der sequenzweite Forget-Loss. Die Zielrelation wurde unter denselben Optimierungshyperparametern somit deutlich stärker geschwächt.

Da bei sämtlichen Updates die ungeclippte Gradientennorm oberhalb der Clipping-Grenze lag, lässt sich die stärkere Zielschwächung des token-selektiven Ansatzes nicht allein auf eine größere Gradientennorm zurückführen. Die Loss-Definitionen unterscheiden sich vielmehr auch in der Richtung und parameterweisen Verteilung der resultierenden Gradienten. Diese Unterschiede wurden im Rahmen der vorliegenden Arbeit nicht weiter zerlegt.

8.2 Zweite Forschungsfrage – Selektivität und Kollateraleffekte

Im ausgewählten Matched-Forgetting-Paar ist die nahezu identische Zielschwächung beim token-selektiven Modellzustand mit deutlich geringeren Veränderungen der übrigen Positionen der Forget-Sequenzen und einer geringeren Veränderung des Validierungsverlusts verbunden.

Der Vergleich kontrolliert dabei für die beobachtete Zielschwächung, nicht jedoch für den Optimierungspfad: Die beiden Zustände wurden mit unterschiedlichen Lernraten und nach fünf beziehungsweise zehn Updates erreicht. Die Unterschiede können daher nicht ausschließlich kausal der Loss-Granularität zugeschrieben werden.

Damit zeigen die Ergebnisse zwei unterschiedliche Ebenen von Selektivität. Der token-selektive Forget-Loss begrenzt die unmittelbare Loss-Veränderung innerhalb der bearbeiteten Trainingssequenzen sehr effektiv auf die annotierten Zielpositionen. Daraus folgt jedoch nicht, dass auch semantisch oder relational benachbarte faktische Assoziationen stabiler bleiben.

Bemerkenswert ist, dass sich die stärkere Veränderung nicht relationstragender Tokenpositionen beim sequenzweiten Forget-Loss nicht in entsprechend stärkeren Veränderungen der `same_window`-Kontrollfakten widerspiegelt. Obwohl diese Fakten innerhalb der unmittelbar bearbeiteten Trainingsfenster auftreten, bleibt ihre mittlere NLL bei beiden Varianten nahezu unverändert.

Eine mögliche Erklärung liegt darin, dass ein einzelnes Faktum innerhalb eines 1024-Token-Fensters nur über wenige Vorhersagepositionen zum sequenzweiten

Forget-Loss beiträgt. Zudem ist aus dem gemeinsamen Auftreten in einem Forget-Fenster nicht abzuleiten, dass dieses Fenster die einzige Trainingsgrundlage des jeweiligen Fakts darstellt. Weitere oder redundante Evidenzstellen im Korpus können dessen Verhalten zusätzlich stabilisieren. Da die vollständige Evidenzbasis der `same_window`-Fakten nicht untersucht wurde, lässt sich dieser Mechanismus anhand der vorliegenden Ergebnisse jedoch nicht eindeutig bestimmen.

Auffällig ist insbesondere die stärkere Veränderung der inversen `same_relation`-Kontrollen beim token-selektiven Modellzustand, während sich die direkte Relationsrichtung zwischen beiden Varianten nur gering unterscheidet. Eine mögliche Erklärung liegt in der Struktur der Forget-Evidenz. Von den 16 ausgewählten Evidenzstellen formulieren acht die Zielrelation explizit in inverser Richtung, und beim token-selektiven Forget-Loss werden wiederholt Entitätspositionen innerhalb solcher relationalen Kontexte adressiert.

Da autoregressive Sprachmodelle die beiden Relationsrichtungen als unterschiedliche bedingte Vorhersagen verarbeiten, ist denkbar, dass diese Updates teilweise auf vergleichbar formulierte inverse Hauptstadtbeziehungen übergreifen. Die vorliegende Fallstudie erlaubt jedoch keine kausale Zuordnung dieses Effekts. Hierfür wären zusätzliche Zielrelationen sowie ein kontrollierter Vergleich unterschiedlich orientierter Forget-Evidenz erforderlich. Auch die übrigen Ergebnisse zu den Kontrollfakten sprechen gegen einen durchgängigen Selektivitätsvorteil des token-selektiven Ansatzes. So fiel insbesondere die Veränderung der `same_object`-Kontrolle beim token-selektiven Modellzustand stärker aus.

Ein ähnliches Bild ergibt sich bei der Counterfactual-Auswertung. Zwar wurden die korrekten Zielsequenzen in allen untersuchten Zuständen stärker geschwächt als die ausgewählten falschen Alternativen. Im Matched-Forgetting-Vergleich wurden die Counterfactual-Targets beim token-selektiven Zustand jedoch etwas stärker verändert als beim Full-Sequence-Zustand, obwohl die Target- Δ NLL nahezu identisch war. Auch diese ergänzende Auswertung zeigt damit keinen durchgängigen Selektivitätsvorteil des token-selektiven Ansatzes.

Die Ergebnisse zeigen damit, dass Selektivität des Unlearning-Eingriffs nicht als eindimensionale Eigenschaft betrachtet werden sollte. Tokenbezogene Selektivität innerhalb der Forget-Sequenzen, Veränderungen alternativer Zielsequenzen und Kollateraleffekte auf andere faktische Informationen erfassen unterschiedliche Ebenen des Modellverhaltens.

Ein Forget-Loss kann innerhalb einer Trainingssequenz sehr gezielt auf einzelne Zielpositionen beschränkt sein und dennoch Assoziationen beeinflussen, die semantisch oder relational mit dem Zielfakt verbunden sind.

8.3 Dritte Forschungsfrage – Einordnung des Referenzmodells

Das Referenzmodell untersucht, wie sich das Modellverhalten verändert, wenn die 16 identifizierten expliziten Löschspans bereits vor dem Training aus dem Korpus entfernt werden. Die Entfernung dieser Spans führte zu einer deutlichen Abschwächung der Zielrelation in der direkten Abfragerichtung, während die inverse Richtung wesentlich geringer verändert wurde. Gleichzeitig blieb der vollständige Validierungsverlust nahezu unverändert.

Die beobachtete Abschwächung der Zielrelation ist damit vereinbar mit einem messbaren Beitrag der entfernten Löschräume zum späteren Modellverhalten. Sie zeigt jedoch nicht, dass diese Räume die vollständige kausale Trainingsgrundlage der Relation bilden. Insbesondere die weiterhin messbare Ziellassoziations- und die deutlich geringere Veränderung in inverser Richtung sprechen dafür, dass weitere direkte, indirekte oder redundante Trainingssignale vorhanden sein können.

Das Referenzmodell ist deshalb nicht als Nachweis einer vollständigen Entfernung der Relation zu interpretieren. Es bildet vielmehr eine Referenz dafür, welcher Modellzustand bei erneutem Training auf einem Korpus entsteht, aus dem die identifizierten expliziten Löschräume entfernt wurden. Der Vergleich mit diesem Zustand ermöglicht eine differenziertere Einordnung des Gradient-Ascent-Unlearnings als ein Vergleich ausschließlich mit dem ursprünglichen Basismodell.

Auffällig ist zudem, dass M_{ref} trotz nahezu unverändertem vollständigem Validierungsverlust bei mehreren Kontrollgruppen deutliche NLL-Veränderungen gegenüber M_0 zeigt. Dies verdeutlicht, dass eine ähnliche globale Sprachmodellleistung keine lokale Verhaltensgleichheit bei einzelnen faktischen Assoziationen impliziert.

Da die ursprüngliche Modellinitialisierung von M_0 für das Referenztraining nicht reproduziert werden konnte, stellen M_0 und M_{ref} unabhängig trainierte Modellzustände dar. Unterschiede zwischen ihnen können daher sowohl mit dem veränderten Trainingskorpus als auch mit stochastischen Unterschieden der Trainingsläufe zusammenhängen. M_{ref} dient deshalb nicht als kausaler Goldstandard, sondern als empirischer Retraining-Referenzzustand.

Die drei Teilfragen sind damit für die untersuchte Fallstudie beantwortet. Die folgenden Abschnitte grenzen ein, inwieweit diese Befunde über den konkreten Versuchsaufbau hinaus interpretiert werden können.

8.4 Bedeutung und Grenzen des kontrollierten Trainingskorpus

Der bekannte Trainingskorpus bildet eine wesentliche Voraussetzung für den gewählten Versuchsaufbau. Er ermöglicht es, die untersuchte Zielrelation mit konkreten Trainingsbelegen zu verknüpfen und dieselben Evidenzstellen als Ausgangspunkt für Full-Sequence GA, token-selektives GA und die Konstruktion des Referenzkorpus zu verwenden.

Darüber hinaus erlaubt die Korpuskenntnis eine differenziertere Evaluation möglicher Kollateraleffekte. Neben inhaltlich und relational verwandten Fakten können mit `same_window` Informationen betrachtet werden, deren gemeinsames Auftreten mit der Forget-Evidenz im tatsächlichen Trainingskorpus bekannt ist. Die beobachteten Modelländerungen lassen sich dadurch aus mehreren Perspektiven auf ihre Selektivität untersuchen.

Der kontrollierte Aufbau bedeutet jedoch nicht, dass sämtliche Trainingsursachen des beobachteten Faktenwissens bekannt sind. Die identifizierten Evidenzstellen entsprechen den durch die verwendete Suchstrategie erfassten expliziten Belegen. Indirekte, redundante oder anders formulierte Evidenz kann weiterhin im Trainingskorpus vorhanden sein.

8.5 Übertragbarkeit auf personenbezogene Informationen und größere Sprachmodelle

Ein Teil personenbezogener Informationen lässt sich als faktische Zuordnung zwischen einer Person und einem Attribut darstellen, beispielsweise zwischen einer Person und einer Adresse oder einem anderen Identifikator. Die vorliegende Fallstudie zeigt, dass die Granularität des Forget-Losses die Kollateraleffekte eines Unlearning-Eingriffs beeinflussen kann. Die beobachteten Kollateraleffekte auf relational eng verbundene Fakten zeigen, dass die gezielte Schwächung einer Assoziation auch andere Verknüpfungen derselben Entitäten beeinflussen kann. Für personenbezogene Informationen wäre ein vergleichbarer Effekt insbesondere dann relevant, wenn mehrere Attribute mit derselben Person verknüpft sind. Die vorliegende Fallstudie untersucht solche personenbezogenen Strukturen jedoch nicht unmittelbar. Personenbezogene Informationen können zusätzlich unterschiedliche Schreibweisen, seltene Identifikatoren und mehrteilige Tokenfolgen aufweisen und unter anderen Extraktionsbedingungen relevant werden. Die Ergebnisse können deshalb nicht als empirischer Nachweis für die Übertragbarkeit des untersuchten Verfahrens auf PII interpretiert werden.

Die Untersuchung wurde ausschließlich an einem selbst trainierten Modell mit rund 163 Millionen Parametern durchgeführt. Aus den Ergebnissen kann daher nicht abgeleitet werden, dass größere Sprachmodelle auf dieselben Loss-Definitionen, Lernraten oder Unlearning-Schritte in vergleichbarer Weise reagieren.

Eine empirische Überprüfung auf Modellen im Milliardenparameterbereich war im Rahmen dieser Arbeit aufgrund des erforderlichen Trainings- und Evaluationsaufwands nicht vorgesehen. Die externe Übertragbarkeit der beobachteten Effekte bleibt daher offen.

8.6 Rechtliche Einordnung

Die technischen Ergebnisse erlauben keine abschließende Aussage darüber, ob durch den untersuchten Eingriff ein konkreter datenschutzrechtlicher Löschan-spruch erfüllt wäre. Gemessen wurden Veränderungen des Modellverhaltens anhand definierter Prompt-Ziel-Paare sowie der allgemeinen Modell-Utility. Eine Verringerung der Wahrscheinlichkeit bestimmter Zielsequenzen belegt weder eine vollständige Entfernung des Einflusses zugrunde liegender Trainingsdaten noch die Nichtextrahierbarkeit der Information unter beliebigen anderen Eingaben [6,9].

Technische Unlearning-Eigenschaften sind deshalb nicht mit dem Nachweis einer rechtlich vollständigen Löschung gleichzusetzen. Die vorliegende Arbeit bewertet die technische Veränderung des Modellverhaltens und keine rechtliche Compliance.

9 Fazit und Ausblick

Diese Arbeit untersuchte, wie die Granularität des Forget-Losses das Gradient-Ascent-basierte Unlearning einer kontrollierten faktischen Relation beeinflusst.

Als experimenteller Ausgangspunkt wurde ein selbst trainiertes autoregressives Sprachmodell verwendet, dessen vollständiger Trainingskorpus bekannt ist. Dadurch konnten explizite Trainingsbelege für die untersuchte Relation identifiziert, dieselben Evidenzfenster für zwei Gradient-Ascent-Varianten verwendet und zusätzlich ein Referenzmodell auf einem gezielt veränderten Trainingskorpus trainiert werden.

Hinsichtlich der ersten Forschungsfrage zeigen die Experimente einen deutlichen Einfluss der Loss-Granularität auf die Schwächung der Zielrelation. Unter identischen Lernraten und derselben Anzahl an Updates erhöhte der token-selektive Forget-Loss die NLL der Zielrelation wesentlich stärker als der sequenzweite Loss. Die beiden Loss-Definitionen schwächen die Zielrelation unter identischen Optimierungsbedingungen somit unterschiedlich stark. Für die Beurteilung der Selektivität wurde deshalb zusätzlich ein Vergleich von Modellzuständen mit nahezu identischer Target- Δ NLL durchgeführt.

Für die zweite Forschungsfrage ergibt sich ein differenziertes Bild. Bei vergleichbarer Zielschwächung veränderte der token-selektive Modellzustand die nicht relationstragenden Positionen der Forget-Sequenzen deutlich weniger als der sequenzweite Zustand. Auch die Veränderung des vollständigen Validierungsverlusts blieb beim token-selektiven Zustand näher an null. Auf Ebene anderer faktischer Informationen zeigte sich jedoch kein durchgängiger Selektivitätsvorteil. Insbesondere anderes Wissen über Islamabad sowie inverse Hauptstadtbeziehungen wurden beim token-selektiven Zustand teilweise stärker verändert.

Auch innerhalb der Zielprompts zeigt die Counterfactual-Auswertung keinen durchgängigen zusätzlichen Selektivitätsvorteil des token-selektiven Ansatzes. Die Kontrollfakten zeigen darüber hinaus, dass die höhere tokenbezogene Selektivität nicht automatisch mit geringeren Veränderungen anderer faktischer Assoziationen einhergeht. Tokenbezogene Selektivität innerhalb der bearbeiteten Trainingssequenzen und Kollateraleffekte auf Kontrollfakten sind daher getrennt zu betrachten.

Zur dritten Forschungsfrage liefert das neu trainierte Referenzmodell einen zusätzlichen empirischen Vergleichszustand. Nach dem Training auf dem modifizierten Korpus zeigt M_{ref} insbesondere in der direkten Relationsrichtung von Pakistan zu Islamabad eine deutliche Abschwächung gegenüber M_0 , während die inverse Richtung wesentlich näher am Ausgangsmodell bleibt. Gleichzeitig bleibt die Modell-Utility weitgehend erhalten. Da die verwendete Korpussuche jedoch nicht sämtliche mögliche Evidenz zur Zielrelation ausschließen kann und die ursprüngliche Modellinitialisierung nicht reproduziert werden konnte, ist das Referenzmodell weder als kausaler Goldstandard noch als Nachweis exakten Unlearnings zu interpretieren.

Die Hauptforschungsfrage lässt sich damit dahingehend beantworten, dass die Granularität des Forget-Losses die Stärke der Zielschwächung wesentlich beeinflusst. Hinsichtlich der Selektivität zeigen die untersuchten Modellzustände unterschiedliche Muster auf verschiedenen Evaluationsebenen. Eine Beschränkung des Losses auf relationstragende Tokenpositionen kann die Modelländerung innerhalb der bearbeiteten Trainingssequenzen stärker auf diese Positionen konzentrieren.

Dieser Vorteil geht jedoch nicht zwangsläufig mit geringeren Kollateraleffekten auf andere faktische Informationen einher.

Die Aussagekraft dieser Ergebnisse ist auf die kontrollierte Fallstudie, das verwendete Modell mit rund 163 Millionen Parametern und die untersuchte nicht-personenbezogene Relation begrenzt. Die beobachtete Verringerung der Wahrscheinlichkeit einer Zielinformation belegt weder die vollständige Entfernung des Einflusses zugrunde liegender Trainingsdaten noch ihre Nichtextrahierbarkeit unter beliebigen anderen Eingaben. Ebenso stellen die Ergebnisse keinen empirischen Nachweis für die Übertragbarkeit des untersuchten Verfahrens auf personenbezogene Informationen oder für die Erfüllung datenschutzrechtlicher Löschanforderungen dar. Für den Anwendungskontext personenbezogener Informationen verdeutlichen sie vielmehr, dass die konkrete Definition des Forget-Losses die Stärke und die Kollateraleffekte eines Unlearning-Eingriffs wesentlich mitbestimmen kann.

Weiterführende Untersuchungen sollten den Versuchsaufbau auf mehrere Zielrelationen übertragen und dabei Eigenschaften wie Ausgangs-NLL, Tokenisierung und Häufigkeit expliziter Trainingsbelege systematisch variieren. Darüber hinaus wäre zu untersuchen, ob sich die beobachteten Effekte bei anderen Unlearning-Zielfunktionen, bei größeren Sprachmodellen und unter breiteren Extraktions- und Robustheitstests reproduzieren lassen. Dadurch ließe sich genauer bestimmen, inwieweit die in dieser Fallstudie beobachteten Unterschiede eine allgemeine Eigenschaft der Loss-Granularität oder eine Besonderheit des konkreten Versuchsaufbaus darstellen.

A Zusätzliche Ergebnisdaten

Tabelle 16. Vollständiger Validierungsverlust der Step-16-Modellzustände

Modell	Lernrate	ΔL_{val}	PPL-Änderung
Full-Sequence	1×10^{-6}	-0,00007	-0,007 %
Full-Sequence	5×10^{-6}	0,00011	+0,011 %
Full-Sequence	1×10^{-5}	0,00211	+0,211 %
Full-Sequence	$1,5 \times 10^{-5}$	0,00836	+0,839 %
Full-Sequence	2×10^{-5}	0,02470	+2,501 %
Full-Sequence	3×10^{-5}	0,19015	+20,943 %
Token-selektiv	1×10^{-6}	-0,00018	-0,018 %
Token-selektiv	5×10^{-6}	0,00124	+0,124 %
Token-selektiv	1×10^{-5}	0,00846	+0,849 %
Token-selektiv	$1,5 \times 10^{-5}$	0,02323	+2,350 %
Token-selektiv	2×10^{-5}	0,04850	+4,969 %
Token-selektiv	3×10^{-5}	0,15770	+17,081 %

B Löschspans des Referenzmodells

Tabelle 17 zeigt die für das Referenzmodell definierten Textspans, die aus dem ursprünglichen Trainingskorpus entfernt wurden. Die Spans sind den jeweiligen Evidenzfenstern über ihre Window-ID zugeordnet.

Tabelle 17: Löschspans der 16 Evidenzfenster des Referenzmodells

Window-ID	Löschspan
873	The capital of Pakistan is Islamabad, but before 1960, it was Karachi, which is now the country’s largest city.
3807	Islamabad (, “abode of Islam”) is the Federal capital city of Pakistan.
6181	, the capital of Pakistan
6958	, the capital of Pakistan
9223	Pakistan’s capital city of
9318	the national capital
9381	the capital
9469	, the capital city of Pakistan
9485	, the capital of Pakistan
9937	, the capital of Pakistan
20056	, the capital of Pakistan
21737	the Pakistani capital of

Tabelle 17 – Fortsetzung

Window-ID Löschspan	
22589	the capital city of Pakistan,
28362	Being the main airport for the Pakistani capital
34359	the capital,
37114	Pakistan's capital

C Klassifizierte Kandidatenfenster

Im Rahmen der Evidenzanalyse wurden 35 durch die Suchheuristik identifizierte Trainingsfenster manuell klassifiziert. Tabelle 18 dokumentiert für jedes Fenster die zugewiesene Kategorie und einen auf die Klassifikation reduzierten Textausschnitt. Auslassungen innerhalb der ursprünglichen 1024-Token-Fenster sind durch „[...]“ gekennzeichnet.

Tabelle 18: Klassifizierte Kandidatenfenster der Evidenzanalyse

Window-ID	Klassifikation	Textausschnitt
873	explicit_direct	The capital of Pakistan is Islamabad, but before 1960, it was Karachi.
3690	false_positive	In Pakistan he is called "Quaid-e-Azam". [...] Another university in Islamabad is named after Quaid-e-Azam University. [...] one of the highways of its capital city Tehran [...]
3807	explicit_inverse	Islamabad [...] is the Federal capital city of Pakistan.
4487	false_positive	Panjab region is divided in [...] Panjab (Pakistan), Islamabad Capital Territory (Pakistan), Panjab (India), Haryana.
6181	explicit_inverse	The Lal Masjid [...] complex in Islamabad, the capital of Pakistan [...]
6958	explicit_inverse	The Faisal Mosque is a mosque in Islamabad, the capital of Pakistan.
8209	false_positive	Chitral [...] is in Pakistan. [...] Regular flights from Peshawar and Islamabad are run by the PIA.
8905	false_positive	Azad Jammu & Kashmir is administered by Pakistan from Islamabad.
9106	historical	The federal government moved in 1959 from Karachi to Rawalpindi (provisional capital until Islamabad was finished).
9164	historical	It was the capital of Pakistan 1947–59, when it was replaced by Islamabad.

Fortsetzung auf der nächsten Seite

Tabelle 18 – Fortsetzung

Window-ID	Klassifikation	Textausschnitt
9223	explicit_direct	Rawalpindi [...] is a city [...] near Pakistan's capital city of Islamabad.
9318	explicit_other	Bahawalpur [...] is situated [...] about 700 km from the national capital Islamabad.
9325	false_positive	Kot Addu [...] is [...] in Pakistan [...] about 866 km from Karachi, 600 km from Islamabad [...].
9381	explicit_other	Dhudial [...] in the Punjab Province of Pakistan [...] is located [...] about 70 km south of the capital Islamabad.
9469	explicit_inverse	The territory includes Islamabad, the capital city of Pakistan.
9483	false_positive	Murree [...] is [...] in Punjab, Pakistan. [...] one can see the cities of Rawalpindi and Islamabad.
9485	explicit_inverse	It is about two and a half hours car drive away from Islamabad, the capital of Pakistan.
9642	false_positive	Malam Jabba [...] is [...] in Pakistan. It is 314 km from Islamabad [...].
9937	explicit_inverse	Gujar Khan [...] is about 55 kilometres southeast of Islamabad, the capital of Pakistan [...].
10646	false_positive	West Punjab was a former province of Pakistan [...] including [...] the Islamabad Capital Territory. The capital was [...] Lahore.
16184	false_positive	Capital Dynamos is [...] for the Islamabad Capital Territory in Pakistan.
16587	historical	The federal government moved the country's capital in 1959 from Karachi to Rawalpindi (serving as provisional capital until Islamabad was finished).
16779	false_positive	Salmaan Taseer [...] was the Governor of Punjab, in Pakistan. He was shot dead in 2011 in Islamabad [...].
20056	explicit_inverse	Islamabad High Court, located in Islamabad, the capital of Pakistan, was established under [...].
21737	explicit_other	Taxila (now ruins near the Pakistani capital of Islamabad).
22589	explicit_direct	Zong [...] is based in the capital city of Pakistan, Islamabad.
24335	false_positive	Survey of Pakistan is the national mapping agency of Pakistan. [...] headquarters [...] in Islamabad.
27340	false_positive	Pakistan Secretariat [...] is the headquarter of the Cabinet and Government of Pakistan. It is located [...] in Islamabad.

Fortsetzung auf der nächsten Seite

Tabelle 18 – Fortsetzung

Window-ID	Klassifikation	Textausschnitt
28362	explicit_inverse	Being the main airport for the Pakistani capital it often hosts officials [...].
28690	false_positive	Capital Development Authority [...] is responsible for providing basic services in Islamabad Capital Territory.
32676	false_positive	This was the first time in Pakistan’s history [...] Seth died [...] in Islamabad [...].
34359	explicit_other	Her death caused an outcry in Pakistan. [...] approximately 580 kilometres from the capital, Islamabad.
34438	false_positive	Rose and Jasmine Garden is [...] located [...] in Islamabad, Capital Territory, Pakistan.
34452	false_positive	The Pakistan Monument [...] is [...] located [...] in Islamabad, Pakistan.
37114	explicit_other	The earthquake [...] was felt [...] in Pakistan’s capital Islamabad [...].

D Vollständige Evaluationsprompts

Tabelle 19 enthält sämtliche für die Faktenevaluation verwendeten Prompt-Ziel-Paare. Zur kompakteren Darstellung werden Prompt und Zielsequenz in einer gemeinsamen Spalte angegeben. Die Kürzel S→O und O→K bezeichnen Subjekt-zu-Objekt- beziehungsweise Objekt-zu-Kontext-Abfragen.

Tabelle 19: Vollständige Prompt- und Zielsequenzen der Faktenevaluation

Gruppe	Fakt	Prompt → Zielsequenz	Richtung
target	Pakistan – capital – Islamabad	„The capital of Pakistan is“ → „Islamabad“	direkt
target	Pakistan – capital – Islamabad	„The capital city of Pakistan is“ → „Islamabad“	direkt
target	Pakistan – capital – Islamabad	„Pakistan’s capital is“ → „Islamabad“	direkt
target	Pakistan – capital – Islamabad	„Islamabad is the capital of“ → „Pakistan“	invers
target	Pakistan – capital – Islamabad	„Islamabad serves as the capital of“ → „Pakistan“	invers
same_subject	Pakistan – located in region – South Asia	„Pakistan is a country in“ → „South Asia“	S→O

Fortsetzung auf der nächsten Seite

Tabelle 19 – Fortsetzung

Gruppe	Fakt	Prompt → Zielsequenz	Richtung
same_subject	Pakistan – currency – Pakistani rupee	„The currency of Pakistan is the“ → „Pakistani rupee“	S→O
same_subject	Pakistan – currency – Pakistani rupee	„Pakistan uses the“ → „Pakistani rupee“	S→O
same_subject	Pakistan – independence_year – 1947	„Pakistan became independent in“ → „1947“	S→O
same_object	Islamabad – located_in_country – Pakistan	„Islamabad is a city in“ → „Pakistan“	S→O
same_window	Alan Moore – occupation – writer (Window 9469)	„Alan Moore is an English“ → „writer“	S→O
same_relation	Sweden – capital – Stockholm	„The capital of Sweden is“ → „Stockholm“	direkt
same_relation	Sweden – capital – Stockholm	„The capital city of Sweden is“ → „Stockholm“	direkt
same_relation	Sweden – capital – Stockholm	„Stockholm is the capital of“ → „Sweden“	invers
same_relation	Japan – capital – Tokyo	„The capital of Japan is“ → „Tokyo“	direkt
same_relation	Japan – capital – Tokyo	„The capital city of Japan is“ → „Tokyo“	direkt
same_relation	Japan – capital – Tokyo	„Tokyo is the capital of“ → „Japan“	invers
same_relation	Finland – capital – Helsinki	„The capital of Finland is“ → „Helsinki“	direkt
same_relation	Finland – capital – Helsinki	„The capital city of Finland is“ → „Helsinki“	direkt
same_relation	Finland – capital – Helsinki	„Helsinki is the capital of“ → „Finland“	invers
same_relation	Austria – capital – Vienna	„The capital of Austria is“ → „Vienna“	direkt
same_relation	Austria – capital – Vienna	„The capital city of Austria is“ → „Vienna“	direkt
same_relation	Austria – capital – Vienna	„Vienna is the capital of“ → „Austria“	invers
same_relation	France – capital – Paris	„The capital of France is“ → „Paris“	direkt
same_relation	France – capital – Paris	„The capital city of France is“ → „Paris“	direkt
same_relation	France – capital – Paris	„Paris is the capital of“ → „France“	invers

Fortsetzung auf der nächsten Seite

Tabelle 19 – Fortsetzung

Gruppe	Fakt	Prompt → Zielsequenz	Richtung
same_relation	Germany – capital – Berlin	„The capital of Germany is“ → „Berlin“	direkt
same_relation	Germany – capital – Berlin	„The capital city of Germany is“ → „Berlin“	direkt
same_relation	Germany – capital – Berlin	„Berlin is the capital of“ → „Germany“	invers
same_relation	Philippines – capital – Manila	„The capital of the Philippines is“ → „Manila“	direkt
same_relation	Philippines – capital – Manila	„The capital city of the Philippines is“ → „Manila“	direkt
same_relation	Philippines – capital – Manila	„Manila is the capital of“ → „the Philippines“	invers
unrelated	Bob Ross – nationality – American	„Bob Ross was an“ → „American“	S→O
unrelated	Claude Monet – occupation – painter	„Claude Monet was a famous“ → „painter“	S→O
unrelated	Jupiter – largest _ planet – Solar System	„The largest planet in the Solar System is“ → „Jupiter“	S→O
unrelated	Jupiter – largest _ planet – Solar System	„Jupiter is the largest planet in the“ → „Solar System“	O→K
same_subject	Pakistan – official _ religion – Islam	„The official religion of Pakistan is“ → „Islam“	S→O
same_window	Robert Urich – occupation – actor (Window 6181)	„Robert Urich was an Emmy-winning“ → „actor“	S→O
same_window	Jennie Kim – occupation – singer (Window 28362)	„Jennie Kim is a South Korean“ → „singer“	S→O
same_window	2013 FIFA U-20 World Cup – winner – France (Window 34359)	„The 2013 FIFA U-20 World Cup was won by“ → „France“	S→O

Direkte und inverse Prompts der Zielrelation werden in der Auswertung getrennt aggregiert. Für die ergänzende Counterfactual-Auswertung werden je Orientierung zusätzlich die in Tabelle 20 aufgeführten alternativen Zielsequenzen verwendet.

Tabelle 20. Counterfactual-Zielsequenzen der Zielrelation

Orientierung korrekte Zielsequenz Counterfactual-Zielsequenzen		
direkt	Islamabad	Hyderabad, Kasur, Mirpur
invers	Pakistan	Kazakhstan, Myanmar, Nepal

E Vollständige Mask-Annotationen

Tabelle 21 dokumentiert die für den token-selektiven Forget-Loss verwendeten Annotationen aller 16 Forget-Fenster. Der Evidenzausschnitt entspricht dem im Annotationsdatensatz hinterlegten Ankertext; die Spalte „Ziel“ gibt diejenige Prediction-Position an, die zum Forget-Loss beiträgt.

Tabelle 21: Vollständige Mask-Annotationen des token-selektiven Forget-Losses

Window- ID	Form	Evidenzausschnitt	Ziel
873	direkt	„The capital of Pakistan is Islamabad“	„Islamabad“
3807	invers	„Islamabad (, 'abode of Islam') is the Federal capital city of Pakistan“	„Pakistan“
6181	invers	„in Islamabad, the capital of Pakistan“	„Pakistan“
6958	invers	„in Islamabad, the capital of Pakistan“	„Pakistan“
9223	direkt	„near Pakistan's capital city of Islamabad“	„Islamabad“
9318	sonstig	„from the national capital Islamabad“	„Islamabad“
9381	sonstig	„south of the capital Islamabad“	„Islamabad“
9469	invers	„includes Islamabad, the capital city of Pakistan“	„Pakistan“
9485	invers	„away from Islamabad, the capital of Pakistan“	„Pakistan“
9937	invers	„southeast of Islamabad, the capital of Pakistan“	„Pakistan“
20056	invers	„located in Islamabad, the capital of Pakistan“	„Pakistan“
21737	sonstig	„near the Pakistani capital of Islamabad“	„Islamabad“
22589	direkt	„based in the capital city of Pakistan, Islamabad“	„Islamabad“
28362	anaphorisch	„Being the main airport for the Pakistani capital“	„capital“
34359	sonstig	„from the capital, Islamabad“	„Islamabad“
37114	sonstig	„Pakistan's capital Islamabad“	„Islamabad“

F Quellcode und Reproduzierbarkeit

Die im Rahmen der experimentellen Untersuchung verwendeten und für die Veröffentlichung bereinigten Jupyter-Notebooks sowie die zugehörigen Benchmark-Artefakte sind in einem öffentlichen GitHub-Repository verfügbar:

`https://github.com/Iffnar/machine-unlearning-loss-granularity.git`

Das Repository umfasst das Vortraining des Basismodells, die Korpus- und Kandidatensuche, die Prä-Evaluation, die Gradient-Ascent-Unlearning-Läufe, das Training des Referenzmodells sowie die abschließende Ergebnisanalyse.

Literatur

1. Bengio, Y., Ducharme, R., Vincent, P., Jauvin, C.: A neural probabilistic language model. *Journal of machine learning research* **3**(Feb), 1137–1155 (2003)
2. Bourtole, L., Chandrasekaran, V., Choquette-Choo, C.A., Jia, H., Travers, A., Zhang, B., Lie, D., Papernot, N.: Machine Unlearning. In: 2021 IEEE Symposium on Security and Privacy (SP). pp. 141–159. IEEE, San Francisco, CA, USA (May 2021). <https://doi.org/10.1109/SP40001.2021.00019>, <https://ieeexplore.ieee.org/document/9519428/>
3. Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J.D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., Amodei, D.: Language Models are Few-Shot Learners. In: Larochelle, H., Ranzato, M., Hadsell, R., Balcan, M.F., Lin, H. (eds.) *Advances in Neural Information Processing Systems*. vol. 33, pp. 1877–1901. Curran Associates, Inc. (2020), https://proceedings.neurips.cc/paper_files/paper/2020/file/1457c0d6bfc4967418bfb8ac142f64a-Paper.pdf
4. Carlini, N., Ippolito, D., Jagielski, M., Lee, K., Tramèr, F., Zhang, C.: Quantifying Memorization Across Neural Language Models. In: *International Conference on Learning Representations* (2023), https://openreview.net/forum?id=TatRHT_1cK
5. Carlini, N., Tramèr, F., Wallace, E., Jagielski, M., Herbert-Voss, A., Lee, K., Roberts, A., Brown, T., Song, D., Erlingsson, Ú., Oprea, A., Raffel, C.: Extracting Training Data from Large Language Models. pp. 2633–2650 (2021), <https://www.usenix.org/conference/usenixsecurity21/presentation/carlini-extracting>
6. Cooper, A.F., Choquette-Choo, C.A., Bogen, M., Klyman, K., Jagielski, M., Filippova, K., Liu, K., Chouldechova, A., Hayes, J., Huang, Y., Triantafillou, E., Kairouz, P., Mitchell, N., Mireshghallah, N., Jacobs, A., Grimmelmann, J., Shmatikov, V., De Sa, C., Shumailov, I., Terzis, A., Barocas, S., Wortman Vaughan, J., Boyd, D., Choi, Y., Koyejo, S., Delgado, F., Liang, P., Ho, D., Samuelson, P., Brundage, M., Bau, D., Neel, S., Wallach, H., Cyphert, A., Lemley, M., Papernot, N., Lee, K.: Machine Unlearning Doesn't Do What You Think: Lessons for Generative AI Policy and Research. In: Belgrave, D., Zhang, C., Lin, H., Pascanu, R., Koniusz, P., Ghassemi, M., Chen, N. (eds.) *Advances in Neural Information Processing Systems*. vol. 38, Main Conference. Curran Associates, Inc. (2025). <https://doi.org/10.52202/085713-2990>, https://proceedings.neurips.cc/paper_files/paper/2025/file/8110ef9878e4642ad848ca583d37d7ca-Paper-Position_Paper_Track.pdf
7. Cosentino, C., Gatto, S., Liò, P., Marozzo, F.: Machine Unlearning: A Perspective, Taxonomy, and Benchmark Evaluation. *Future Internet* **18**(3), 174 (Mar 2026). <https://doi.org/10.3390/fi18030174>, <https://www.mdpi.com/1999-5903/18/3/174>
8. Eldan, R., Russinovich, M.: Who's Harry Potter? Approximate Unlearning in LLMs (Oct 2023). <https://doi.org/10.48550/arXiv.2310.02238>, <http://arxiv.org/abs/2310.02238>
9. European Data Protection Board: Opinion 28/2024 on Certain Data Protection Aspects Related to the Processing of Personal Data in the Context of AI Models (Dec 2024), [https://www.edpb.europa.eu/documents/opinion-of-the-board-art-64/opinion-282024-on-certain-data-protection-aspects-related-to_en](https://www.edpb.europa.eu/documents/opinion-of-the-board/art-64/opinion-282024-on-certain-data-protection-aspects-related-to_en)
10. Feng, X., Chen, C., Li, Y., Lin, Z.: Fine-grained pluggable gradient ascent for knowledge unlearning in language models. In: Al-Onaizan, Y., Bansal, M., Chen, Y.N.

- (eds.) Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. pp. 10141–10155. Association for Computational Linguistics, Miami, Florida, USA (Nov 2024). <https://doi.org/10.18653/v1/2024.emnlp-main.566>, <https://aclanthology.org/2024.emnlp-main.566/>
11. Ginart, A., Guan, M., Valiant, G., Zou, J.: Making AI Forget You: Data Deletion in Machine Learning. In: Wallach, H., Larochelle, H., Beygelzimer, A., Alché-Buc, F.d., Fox, E., Garnett, R. (eds.) Advances in Neural Information Processing Systems. vol. 32. Curran Associates, Inc. (2019), https://proceedings.neurips.cc/paper_files/paper/2019/file/cb79f8fa58b91d3af6c9c991f63962d3-Paper.pdf
 12. Goodfellow, I., Courville, A., Bengio, Y.: Deep learning. Adaptive computation and machine learning, The MIT Press, Cambridge, Massachusetts (2016)
 13. Kingma, D.P., Ba, J.: Adam: A Method for Stochastic Optimization. In: International Conference on Learning Representations (2015), <https://mlanthology.org/iclr/2015/kingma2015iclr-adam/>
 14. Loshchilov, I., Hutter, F.: SGDR: Stochastic Gradient Descent with Warm Restarts. In: International Conference on Learning Representations (2017), <https://mlanthology.org/iclr/2017/loshchilov2017iclr-sgdr/>
 15. Loshchilov, I., Hutter, F.: Decoupled Weight Decay Regularization. In: International Conference on Learning Representations (2019), <https://openreview.net/forum?id=Bkg6RiCqY7>
 16. Lynch, A., Guo, P., Ewart, A., Casper, S., Hadfield-Menell, D.: Eight Methods to Evaluate Robust Unlearning in LLMs. arXiv preprint arXiv:2402.16835 (2024)
 17. Maini, P., Feng, Z., Schwarzschild, A., Lipton, Z.C., Kolter, J.Z.: TOFU: A Task of Fictitious Unlearning for LLMs. In: First Conference on Language Modeling (2024), <https://openreview.net/forum?id=B41hNBowLo>
 18. McCallister, E., Grance, T., Scarfone, K.A.: Guide to protecting the confidentiality of Personally Identifiable Information (PII). Tech. Rep. NIST SP 800-122, National Institute of Standards and Technology, Gaithersburg, MD (2010). <https://doi.org/10.6028/NIST.SP.800-122>, <https://nvlpubs.nist.gov/nistpubs/Legacy/SP/nistspecialpublication800-122.pdf>
 19. Meng, K., Bau, D., Andonian, A., Belinkov, Y.: Locating and Editing Factual Associations in GPT. In: Advances in Neural Information Processing Systems 35. pp. 17359–17372. Neural Information Processing Systems Foundation, Inc. (NeurIPS), New Orleans, Louisiana, USA (2022). <https://doi.org/10.52202/068431-1262>, <http://www.proceedings.com/068431-1262.html>
 20. Meng, K., Sen Sharma, A., Andonian, A., Belinkov, Y., Bau, D.: Mass Editing Memory in a Transformer. The Eleventh International Conference on Learning Representations (ICLR) (2023)
 21. Parii, D., van Osch, T., Sun, C.: Machine Unlearning of Personally Identifiable Information in Large Language Models. In: Aletras, N., Chalkidis, I., Barrett, L., Goanță, C., Preotiuc-Pietro, D., Spanakis, G. (eds.) Proceedings of the Natural Legal Language Processing Workshop 2025. pp. 54–67. Association for Computational Linguistics, Suzhou, China (Nov 2025). <https://doi.org/10.18653/v1/2025.nllp-1.6>, <https://aclanthology.org/2025.nllp-1.6/>
 22. Pascanu, R., Mikolov, T., Bengio, Y.: On the difficulty of training recurrent neural networks. In: Dasgupta, S., McAllester, D. (eds.) Proceedings of the 30th International Conference on Machine Learning. Proceedings of Machine Learning Research, vol. 28, pp. 1310–1318. PMLR, Atlanta, Georgia, USA (Jun 2013), <https://proceedings.mlr.press/v28/pascanu13.html>

23. Radford, A., Narasimhan, K., Salimans, T., Sutskever, I.: Improving Language Understanding by Generative Pre-Training. Technical Report, OpenAI (2018), https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf
24. Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., Sutskever, I.: Language Models are Unsupervised Multitask Learners. Tech. rep., OpenAI (2019), https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf
25. Raschka, S.: Build a Large Language Model (From Scratch). Manning (2024), <https://learning.oreilly.com/library/view/build-a-large/9781633437166/>
26. Rumelhart, D.E., Hinton, G.E., Williams, R.J.: Learning representations by back-propagating errors. *Nature* **323**(6088), 533–536 (Oct 1986). <https://doi.org/10.1038/323533a0>, <https://www.nature.com/articles/323533a0>
27. Sekhari, A., Acharya, J., Kamath, G., Suresh, A.T.: Remember What You Want to Forget: Algorithms for Machine Unlearning. In: *Advances in Neural Information Processing Systems*. vol. 34 (2021)
28. Sennrich, R., Haddow, B., Birch, A.: Neural Machine Translation of Rare Words with Subword Units. In: Erk, K., Smith, N.A. (eds.) *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. pp. 1715–1725. Association for Computational Linguistics, Berlin, Germany (Aug 2016). <https://doi.org/10.18653/v1/P16-1162>, <https://aclanthology.org/P16-1162/>
29. Shalev-Shwartz, S., Ben-David, S.: *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press, 1 edn. (May 2014). <https://doi.org/10.1017/CBO9781107298019>, <https://www.cambridge.org/core/product/identifier/9781107298019/type/book>
30. Shi, W., Lee, J., Huang, Y., Malladi, S., Zhao, J., Holtzman, A., Liu, D., Zettlemoyer, L., Smith, N., Zhang, C.: MUSE: Machine Unlearning Six-Way Evaluation for Language Models. In: Yue, Y., Garg, A., Peng, N., Sha, F., Yu, R. (eds.) *International Conference on Learning Representations*. vol. 2025, pp. 27797–27818 (2025), https://proceedings.iclr.cc/paper_files/paper/2025/file/4556f5398bd2c61bd7500e306b4e560a-Paper-Conference.pdf
31. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I.: Attention is All you Need. In: Guyon, I., Luxburg, U.V., Bengio, S., Wallach, H., Fergus, R., Vishwanathan, S., Garnett, R. (eds.) *Advances in Neural Information Processing Systems*. vol. 30. Curran Associates, Inc. (2017), https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf
32. Wan, Y., Ramakrishna, A., Chang, K.W., Cevher, V., Gupta, R.: Not every token needs forgetting: Selective unlearning balancing forgetting and utility in large language models. In: Christodoulopoulos, C., Chakraborty, T., Rose, C., Peng, V. (eds.) *Findings of the Association for Computational Linguistics: EMNLP 2025*. pp. 1827–1835. Association for Computational Linguistics, Suzhou, China (Nov 2025). <https://doi.org/10.18653/v1/2025.findings-emnlp.96>, <https://aclanthology.org/2025.findings-emnlp.96/>
33. Wang, H., Jing, Y., Sun, H., Wang, Y., Wang, J., Liao, J., Tao, D.: Erasing Without Remembering: Implicit Knowledge Forgetting in Large Language Models. In: Liakata, M., Moreira, V.P., Zhang, J., Jurgens, D. (eds.) *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. pp. 1962–1994. Association for Computational Linguistics, San Diego,

- California, United States (Jul 2026). <https://doi.org/10.18653/v1/2026.acl-long.88>, <https://aclanthology.org/2026.acl-long.88/>
34. Zhang, R., Lin, L., Bai, Y., Mei, S.: Negative Preference Optimization: From Catastrophic Collapse to Effective Unlearning (Oct 2024). <https://doi.org/10.48550/arXiv.2404.05868>, <http://arxiv.org/abs/2404.05868>